

RHEINISCHE FRIEDRICH-WILHELMS-UNIVERSITÄT
BONN

PROJEKTBERICHT

Einsatz von Mikrofonarrays für Interviewaufnahmen

Navid Bahrami und Shajan Miri Razani

s22nbahr@uni-bonn.de und s87smiri@uni-bonn.de

Erstprüfer

Prof. Dr. Matthew Smith

Betreuer

Florin Martius, M.Sc.

Institut für Informatik 4

Behavioral Security Gruppe

30. September 2025

ZUSAMMENFASSUNG

Automatische Meeting-Transkription könnte die Dokumentation erheblich vereinfachen, scheitert aber oft an unzureichender Aufnahmequalität in realistischen Gesprächssituationen. Diese Arbeit untersucht, ob kompakte Mikrofonarrays durch moderne Signalverarbeitung eine praktikable Alternative zu professionellen Aufnahmegeräten darstellen. Im Mittelpunkt steht die Evaluation eines ReSpeaker 4-Mic Array v2.0 im Vergleich zu einem Zoom H4n Pro und einem iPhone 12 mini. Die Audioaufnahmen werden durch SNR-basiertes Kanal-Gating, Wiener-Filtering und Direction-of-Arrival-basiertes Beam-forming optimiert. Die Transkription erfolgt mittels OpenAI Whisper, die Sprecherzuordnung durch pyannote.audio. Die Bewertung erfolgt anhand der Word Error Rate (WER) und des Speaker-Attributed Recall (SA-Recall) in drei realistischen Szenarien: einer ruhigen Vereinssitzung (4 Teilnehmende), einem Interview in lauter Mensa-Umgebung (4 Teilnehmende) sowie einer erweiterten Gruppendiskussion (6 Teilnehmende). In kontrollierten Umgebungen erreicht das Array durch geeignete Nachbearbeitung eine WER von 24.6% und übertrifft damit die Einzelmikrofone (29–31%). In akustisch komplexen Szenarien mit mehreren Sprechern und hohem Störgeräuschpegel zeigen sich jedoch die physikalischen Grenzen kompakter Arrays. Die geringe Apertur von 8 cm führt zu räumlichem Aliasing oberhalb von 2,1 kHz, was die Richtschärfe im Sprachband beeinträchtigt. In solchen Situationen bleiben Einzelmikrofone mit einer WER von 31.6–35.5% deutlich robuster (Array: 45.8%). Die Arbeit liefert empirisch fundierte Kriterien für den praktischen Einsatz kostengünstiger Mikrofonarrays und identifiziert sowohl geeignete Anwendungsfelder (strukturierte Meetings, kontrollierte Interviews) als auch klare Grenzen (großskalige Gruppendiskussionen, stark verrauschte Umgebungen). Die Ergebnisse verdeutlichen, dass für universelle Gesprächstranskription entweder hochwertigere Array-Geometrien mit größerer Apertur oder verteilte Mikrofonsysteme erforderlich sind.

GENERAL STATEMENTS

Teile dieses Berichts wurden mit ChatGPT generiert.

INHALTSVERZEICHNIS

Inhalt	I
Zusammenfassung	I
Inhaltsverzeichnis	II
Abbildungsverzeichnis	II
Tabellenverzeichnis	II
1 Einleitung	1
2 Grundlagen	3
2.1 Beamforming und Mikrofonarray-Technologie	3
2.2 Grundlagen relevanter Signalverarbeitungsverfahren	3
2.2.1 Signal-Rausch-Verhältnis (SNR)	3
2.2.2 Wiener-Filter	4
2.2.3 Direction-of-Arrival (DoA)	4
2.2.4 SRP-PHAT	4
2.3 Integration von Mikrofonarrays mit Whisper ASR	4
2.4 Ergänzende Begriffsdefinitionen	5
2.4.1 Mikrofoncharakteristik	5
2.4.2 Array-Geometrien	5
2.4.2.1 Hauptkeule, Richtkeule und Nebenkeulen	6
2.4.3 Räumliches Aliasing	6
2.4.4 Grating Lobes	6
2.4.5 Reverberation (Nachhall) und DRR	6
2.4.6 Automatic Speech Recognition (ASR)	7
2.4.7 Speaker Diarization	7
2.4.7.1 Short-Time Fourier Transform (STFT)	7
2.4.7.2 Root Mean Square (RMS)	7
2.4.7.3 Dezibel Full Scale (dBFS)	7
2.4.7.4 Musical Noise	7
2.4.7.5 Overlap-Add-Verfahren	7
2.4.7.6 Kreuzkorrelation	8
2.4.7.7 ALSA (Advanced Linux Sound Architecture)	8
2.4.8 Hysteresis in Schwellwertverfahren	8
3 Verwandte Arbeiten	9
3.1 Robuste Beamforming-Verfahren	9
3.2 Mehrsprecher Szenarien und Distributed Arrays	9
3.3 Integration von Mikrofonarrays mit Whisper	10
4 Methodik	11
4.1 Aufnahmegeräte	11
4.1.1 Mikrofonarray (ReSpeaker 4-Mic Array v2.0)	11
4.1.2 Zoom H4n Pro	12
4.1.3 iPhone 12 mini	12
4.2 Raspberry PI	12

4.3	Versuchsaufbau	13
4.3.1	Erster Versuch	13
4.3.2	Zweiter Versuch	13
4.3.3	Dritter Versuch	14
4.4	Computer und Verarbeitungspipeline	14
4.5	Nachbearbeitung durch SNR-basiertes Gating mit Wiener-Postfilter	15
4.5.1	Erweiterung durch DoA-basiertes Beamforming	15
4.6	Parameteroptimierung und Kalibrierung	19
4.6.1	SNR-Gating Parameter	19
4.6.2	DoA-Beamforming Parameter	19
4.6.3	Kalibrierung und Normalisierung	19
4.6.4	Optimierungsprozess	20
4.7	Evaluationsmethodik	21
4.7.1	Referenztranskripte	21
4.7.2	Word Error Rate (WER)	21
4.7.3	Speaker-Attributed Recall (SA-Recall)	22
5	Evaluation	23
5.1	Versuch 1	23
5.1.1	Auswertung Versuch 1	23
5.2	Versuch 2	24
5.2.1	Auswertung Versuch 2	24
5.3	Versuch 3	25
5.3.1	Auswertung Versuch 3	25
5.4	Vergleich der Szenarien	26
6	Diskussion	28
6.1	Reflexion der Metriken	28
6.2	Einordnung in Problemstellung und Forschungsstand	28
6.3	Stärken und Schwächen der Methodik	29
6.4	Praktische Implikationen	29
7	Fazit	31
7.1	Wann das Array Einzelmikrofonen vorzuziehen ist	31
7.2	Wann Einzelmikrofone oder alternative Lösungen nötig sind	31
7.3	Ausblick	32
8	Anhang	I
8.1	Github Repository	I

ABBILDUNGSVERZEICHNIS

Fig. 2.1		5
----------	-----------	---

Fig. 4.1	Schematische Darstellung des Aufnahme- und Verarbeitungsprozesses. Die Teilnehmer:innen sprechen in das Mikrofonarray, das über USB mit dem Raspberry Pi verbunden ist. Der Pi steuert die Aufnahme und speichert die Signale als Mehrkanal-WAV-Datei. Anschließend werden die Kanäle extrahiert und zusammen mit der Originalaufnahme auf einen leistungsstärkeren PC übertragen, wo mittels pyannote.audio die Sprecherdiarisierung und mit Whisper die Transkription durchgeführt werden. Die Ergebnisse werden fusioniert, sodass ein kombiniertes Transkript mit Text und Sprecherlabels entsteht.	12
Fig. 4.2	Schematische Darstellung eines Delay-and-Sum-Beamformers. Die Mikrofonsignale $x_m[n]$ werden entsprechend der laufzeitbedingten Verzögerung $\tau_m(\theta)$ verschoben, gewichtet und anschließend summiert, um das Ausgangssignal $y[n]$ zu erzeugen. Der Pfeil $u(\theta)$ kennzeichnet dabei die Einfallsrichtung der ebenen Welle, aus der das Signal auf das Array trifft.	18
Fig. 4.3	Systematische Parameteroptimierung für SNR-Gating (a), DoA- Beamforming (b) und exponentielle Glättung (c).	20
Fig. 5.1	Vergleich der WER für alle Systeme und Signalverarbeitungen in drei Szenarien (niedriger ist besser).	27
Fig. 5.2	Vergleich des SA-Recall für alle Systeme und Signalverarbeitungen in drei Szenarien (höher ist besser).	27

TABELLENVERZEICHNIS

Tab. 5.1	Vergleich der WER und des SA-Recall verschiedener Aufnahmesysteme und Signalverarbeitungsmethoden im ersten Aufnahmeszenario.	23
Tab. 5.2	Vergleich der WER und des SA-Recall verschiedener Aufnahmesysteme und Signalverarbeitungsmethoden im zweiten Aufnahmeszenario.	24
Tab. 5.3	Vergleich der WER und des SA-Recall verschiedener Aufnahmesysteme und Signalverarbeitungsmethoden im dritten Aufnahmeszenario.	25

1 EINLEITUNG

Besprechungen, Interviews und kollaborative Diskussionen sind ein zentraler Bestandteil akademischer wie auch beruflicher Arbeit. Trotz ihrer Bedeutung wird jedoch ein erheblicher Teil der gesprochenen Inhalte nicht dokumentiert oder nur in stark reduzierter Form als Ergebnisprotokoll festgehalten. Zwar reicht dies oftmals zur Erfassung von Entscheidungen aus, doch gehen dabei wesentliche Aspekte des Gesprächsverlaufs, der Argumentation und der Entscheidungsfindung verloren. Diese Lücken führen nicht nur zu Wissensverlust, sondern erschweren auch die Nachvollziehbarkeit kollektiver Prozesse und können Missverständnisse in der Umsetzung nach sich ziehen.

Klassische Einzelmikrofone stoßen in diesem Kontext schnell an ihre Grenzen. Aufgrund ihrer gerichteten Charakteristik nehmen sie Sprache in hoher Qualität nur aus einer bestimmten Richtung auf, während Stimmen aus anderen Positionen stark abgeschwächt oder gar nicht erfasst werden. Besonders problematisch ist dies in Mehrsprechersituationen wie etwa in Gremiensitzungen oder hybriden Meetings, in denen Sprecher räumlich verteilt sind und zusätzlich Hintergrundgeräusche eine Rolle spielen. [15]

Mikrofonarray-Technologien haben sich in den letzten Jahren als vielversprechender Ansatz etabliert, um diese Defizite zu überwinden. Durch die Kombination mehrerer räumlich verteilter Mikrofone mit modernen Verfahren der Signalverarbeitung können Sprachsignale aus einer Zielrichtung verstärkt und Störquellen gleichzeitig unterdrückt werden. [14] In Verbindung mit automatischer Spracherkennung (Automatic Speech Recognition, ASR) eröffnet dies die Möglichkeit, vollständige, sprecherbezogene Transkripte von Gesprächen zu erstellen. Solche Transkripte gehen über reine Dokumentation hinaus, da sie eine semantische Suche, Informationsretrieval oder weiterführende Analysen des Gesprächsverlaufs ermöglichen. [15]

Gleichzeitig bestehen weiterhin wesentliche Herausforderungen. Klassische Verfahren zeigen Limitierungen bei tiefen Frequenzen, und in lauten oder halligen Szenarien wird eine zuverlässige Sprecherlokalisierung deutlich erschwert [16]. Zudem ist die Stabilität der Sprecherzuordnung kritisch: Ein Transkript ist nur dann von Wert, wenn nicht nur die Wörter korrekt erkannt, sondern diese auch den richtigen Sprechern zugeordnet werden [16]. Damit ergibt sich die Notwendigkeit, Mikrofonarrays nicht nur technisch zu entwickeln, sondern auch systematisch in praxisnahen Szenarien zu evaluieren.

Vor diesem Hintergrund verfolgt diese Arbeit das Ziel, die Leistungsfähigkeit eines kompakten Mikrofonarrays im Vergleich zu etablierten Einzelmikrofonlösungen systematisch zu untersuchen. Die Evaluation erfolgt in mehreren realistischen Szenarien, die unterschiedliche akustische Bedingungen und Gesprächskonstellationen widerspiegeln – von einer ruhigen Besprechungssituation bis hin zu komplexen Mehrsprecherumgebungen. Dadurch soll aufgezeigt werden, in welchen Kontexten Mikrofonarrays einen klaren Vorteil bieten und wo ihre Grenzen liegen.

Die zentralen Beiträge dieser Arbeit lassen sich wie folgt zusammenfassen:

- Systematischer Vergleich eines Mikrofonarrays mit etablierten Einzelmikrofonen in realistischen Gesprächssituationen.
- Aufbau einer reproduzierbaren Aufnahmepipeline, die eine objektive Gegenüberstellung verschiedener Systeme ermöglicht.
- Durchführung mehrerer Experimente in verschiedenen Szenarien (ruhige Umgebung, laute Mensa, erweitertes Mehrsprecher-Szenario).
- Diskussion der Vorteile und Grenzen von Mikrofonarrays im Hinblick auf zukünftige Anwendungen in der automatisierten Gesprächsaufzeichnung.

Mit dieser Arbeit werden empirische Einblicke in die Leistungsfähigkeit und die Limitierungen kleiner Mikrofonarrays für Gesprächs- und Interviewtranskriptionen gewonnen. Die Ergebnisse tragen dazu

bei, das Potenzial dieser Technologie in kontrollierten wie auch herausfordernden Szenarien besser einschätzen zu können und bieten eine Grundlage für weiterführende Forschungsarbeiten zu robusteren Array-Geometrien oder verteilten Aufnahmesystemen.

2 GRUNDLAGEN

Dieses Kapitel legt die theoretische Basis für die in dieser Arbeit durchgeführten Experimente und Auswertungen. Im Mittelpunkt stehen Verfahren und Technologien der Sprachsignalverarbeitung, die eine robuste und verständliche Transkription von Gesprächssituationen ermöglichen. Dazu gehören zunächst die Prinzipien von Mikrofonarrays und Beamforming, mit denen Schallsignale aus unterschiedlichen Richtungen gezielt verarbeitet werden können. Darauf aufbauend werden ausgewählte Signalverarbeitungsverfahren vorgestellt, die eine Verbesserung des Signal-Rausch-Verhältnisses und eine robuste Trennung von Sprecher:innen erlauben. Abschließend wird die Integration solcher Vorverarbeitungstechniken mit modernen Spracherkennungssystemen wie Whisper beschrieben, welches als zentrales ASR-Modell in dieser Arbeit eingesetzt wird.

Ziel dieses Kapitels ist es, die wichtigsten technischen Konzepte so darzustellen, dass ihre Rolle für die späteren Experimente nachvollziehbar wird und die Wahl bestimmter Methoden (z. B. Beamforming, Wiener-Filter oder DoA-Schätzung) begründet.

2.1 BEAMFORMING UND MIKROFONARRAY-TECHNOLOGIE

Mikrofonarrays kombinieren mehrere räumlich verteilte Mikrofone, um Schall aus unterschiedlichen Richtungen zu erfassen [15]. Mithilfe von Signalverarbeitungstechniken wie Beamforming lassen sich Zielquellen verstärken und Störungen aus anderen Richtungen unterdrücken [14]. Ein klassischer Ansatz ist das Delay-and-Sum-Beamforming. Die Mikrofonsignale werden laufzeitkorrigiert ausgerichtet und summiert, sodass Signale aus der Zielrichtung konstruktiv addiert werden, während andere teilweise ausgelöscht werden. Dieses Verfahren ist zwar einfach, weist jedoch eine frequenzabhängige Richtwirkung auf, die insbesondere bei tiefen Frequenzen eingeschränkt ist [15] (vgl. Abschnitt 3.1 für weiterführende Verfahren).

2.2 GRUNDLAGEN RELEVANTER SIGNALVERARBEITUNGSVERFAHREN

Die Qualität von Sprachaufnahmen wird durch Störgeräusche, Nachhall und die räumliche Anordnung der Schallquellen beeinflusst. Um in realistischen Umgebungen wie Meetings oder Interviews robuste und verständliche Sprachsignale zu erhalten, kommen verschiedene Verfahren der digitalen Signalverarbeitung zum Einsatz. Diese Verfahren dienen entweder der Verbesserung des Signal-Rausch-Verhältnisses, der Unterdrückung unerwünschter Störgeräusche oder der gezielten Fokussierung auf einzelne Sprecher:innen durch räumliche Filterung. [15]

Im Folgenden werden die für diese Arbeit besonders relevanten Ansätze vorgestellt. Dazu gehören grundlegende Verfahren zur Bestimmung der Signalqualität, klassische Filtermethoden zur Rauschreduktion sowie Algorithmen zur Richtungsbestimmung und räumlichen Signalverarbeitung. Diese Methoden bilden die theoretische Grundlage für den praktischen Einsatz von Mikrofonarrays in Gesprächssituationen. [16]

2.2.1 SIGNAL-RAUSCH-VERHÄLTNIS (SNR)

Das Signal-Rausch-Verhältnis (SNR) beschreibt das Verhältnis zwischen der Leistung des gewünschten Nutzsignals und der Leistung des Hintergrundrauschens. Ein hohes SNR spricht für eine klare Sprachaufnahme, während ein niedriges SNR auf starke Störungen hinweist. Viele Verfahren der Sprachsignalverarbeitung, wie etwa SNR-basiertes Kanal-Gating, nutzen diesen Wert als Entscheidungsgrundlage für die Auswahl der besten Mikrofonspur. [8]

2.2.2 WIENER-FILTER

Der *Wiener-Filter* ist ein lineares Verfahren zur Rauschunterdrückung. Er minimiert den mittleren quadratischen Fehler zwischen Original- und geschätztem Signal, indem er eine spektrale Verstärkungsfunktion auf Basis von Signal- und Rauschleistungsdichten bestimmt. [24]

Praktische Relevanz: Ein zu aggressiv parametrisiertes Wiener-Filtering kann zwar Rauschen effektiv dämpfen, erzeugt jedoch hörbare Artefakte, die als *musical noise* bezeichnet werden. In realistischen Gesprächsaufnahmen ist dies problematisch, da solche Artefakte die automatische Spracherkennung stärker stören als das verbleibende Rauschen. Daher wird in dieser Arbeit eine „milde“ Variante (vgl. Kapitel 4.5) eingesetzt, die einen Kompromiss zwischen Rauschreduktion und Sprachverständlichkeit bietet. [8]

2.2.3 DIRECTION-OF-ARRIVAL (DOA)

Die *Direction-of-Arrival (DoA)* bezeichnet den Einfallswinkel einer Schallquelle relativ zum Mikrofonarray. Die Schätzung dieser Richtung ermöglicht es, die Signale so zu verzögern und zu kombinieren, dass die Zielquelle konstruktiv verstärkt und Störquellen unterdrückt werden. [10]

Intuition: DoA-Schätzung funktioniert ähnlich wie das menschliche Gehör. Auch der Mensch nutzt Laufzeitunterschiede zwischen linkem und rechtem Ohr, um Richtungen zu bestimmen. Ein Array mit mehreren Mikrofonen kann diese Laufzeitunterschiede noch präziser auswerten, solange die Abstände nicht zu klein oder zu groß sind. [9]

2.2.4 SRP-PHAT

Das Verfahren *Steered Response Power with Phase Transform (SRP-PHAT)* nutzt Kreuzkorrelationen von Mikrofonsignalen im gegebenen Frequenzbereich und gewichtet die Phaseninformation stärker als die Amplitudeninformation. [10]

Intuition: Da Nachhall vor allem die Amplituden verzerrt, bleibt die Phaseninformation vergleichsweise stabil. Dadurch ist SRP-PHAT robuster in halligen Räumen als klassische Verfahren. Allerdings können starke Störgeräusche die Korrelation verfälschen, sodass in sehr lauten Szenarien zusätzliche Stabilisierungsschritte (z. B. Konfidenzgating) nötig sind. [7]

2.3 INTEGRATION VON MIKROFONARRAYS MIT WHISPER ASR

Whisper ist ein quelloffenes Spracherkennungsmodell, das OpenAI im Jahr 2022 veröffentlicht hat. Es vereint Transkription, Sprachübersetzung, Sprachaktivitäts- sowie Spracherkennung in einem System und unterstützt 99 Sprachen. Das Modell wurde mit 680.000 Stunden mehrsprachiger Daten trainiert und liefert selbst in lauten Umgebungen präzise Ergebnisse, auch bei unterschiedlichen Akzenten, Sprachen und Übersprechen. [21, 25]

Obwohl Whisper selbst ein einkanaliges Modell ist, profitiert es von dem verbesserten Signal-Rausch-Verhältnis, das Beamforming oder räumliche Filterung bieten können. [26]

Über Forschungsprototypen hinaus gibt es praktische Bemühungen, Whisper in reale Aufnahmesituationen zu integrieren. So gibt es beispielsweise Open-Source-Projekte und Anleitungen für den Einsatz von Whisper auf Edge-Geräten wie dem Raspberry Pi. Busler (2025) demonstriert eine lokale Sprach-zu-Text-Lösung auf einem Raspberry Pi 5 unter Verwendung von Whisper und stellt fest, dass dessen Offline-Verarbeitung und Geräuschrobustheit ideal für den Einsatz auf dem Gerät sind. [6]

In einer solchen Konfiguration könnte man ein ReSpeaker Mic Array v2.0 an den Pi anschließen und Echtzeit-Beamforming durchführen, um sich auf die Stimme des Sprechers zu konzentrieren, und dann Whisper verwenden, um das beamgeformte Audio zu transkribieren. Die Hardware umfasst ein Array mit vier Mikrofonen und integrierte Algorithmen für Beamforming, DoA-Erkennung (Direction-of-Arrival), Rauschunterdrückung (NS) und akustische Echokompensation (AEC). [23]

Damit bietet die Kombination aus Mikrofonarray und Whisper eine gute technische Grundlage für dieses Projekt, das auf robuste Sprachaufzeichnung und Transkription in unterschiedlichen Situationen abzielt.

2.4 ERGÄNZENDE BEGRIFFSDEFINITIONEN

In den vorherigen Abschnitten wurden zentrale Verfahren der Array-Signalverarbeitung vorgestellt. Für ein vollständiges Verständnis der späteren Experimente ist es hilfreich, weitere Grundbegriffe zu präzisieren.

2.4.1 MIKROFONCHARAKTERISTIK

Die *Mikrofoncharakteristik* beschreibt die richtungsabhängige Empfindlichkeit eines Mikrofons in Abhängigkeit des Einfallswinkels θ . Typische idealisierte Muster sind omnidirektional (gleiche Empfindlichkeit in alle Richtungen), Niere, Superniere und Acht. Diese Muster werden in Abb. 2.1 veranschaulicht. In der Praxis ist die Richtwirkung frequenzabhängig. Mit steigender Frequenz wird die Richtschärfe stärker. Diese Charakteristik beeinflusst maßgeblich die Störschallunterdrückung und ist der Referenzpunkt für die Vorteile von Mikrofonarrays. [18]




Abbildung 2.1:
Beispielhafte Darstellung von Niere, Superniere, Acht und Kugel/Omnidirektional. [12]

2.4.2 ARRAY-GEOMETRIEN

Unter *Array-Geometrie* versteht man die räumliche Anordnung der Mikrofone. Häufige Formen sind lineare Arrays (ULA), kreisförmige Arrays (UCA), rechteckige Anordnungen (URA) sowie verteilte Arrays. Die Geometrie bestimmt die Form der *Richtkeule*, die Lage der *Nebenkeulen* und die erreichbare

Richtschärfe (vgl. Abschnitt 2.4.2.1). Kreis- oder planare Arrays ermöglichen eine 2D- bzw. 3D-DoA-Schätzung, während lineare Arrays primär die Azimut-Richtung erfassen. [27, 16]

2.4.2.1 HAUPTKEULE, RICHTKEULE UND NEBENKEULEN

Unter einer *Keule* versteht man die Region im Richtdiagramm eines Mikrofons oder Mikrofonarrays, in der die Empfindlichkeit erhöht ist.

- Die **Hauptkeule** bezeichnet den Bereich maximaler Verstärkung und gibt die bevorzugte Empfangsrichtung des Arrays an.
- Der Begriff **Richtkeule** wird oft synonym zur Hauptkeule verwendet und beschreibt die Bündelung der Empfindlichkeit in eine Zielrichtung. Die Breite der Richtkeule bestimmt die Richtschärfe: Je schmaler die Keule, desto selektiver kann das Array eine Schallquelle erfassen.
- **Nebenkeulen (Sidelobes)** sind zusätzliche Maxima außerhalb der Hauptkeule. Sie entstehen durch Interferenzeffekte zwischen den Mikrofonen. Idealerweise sind sie stark abgeschwächt, da sie sonst Störquellen aus unerwünschten Richtungen durchlassen.

Das Verhältnis zwischen Haupt- und Nebenkeulenpegeln (Sidelobe Level) ist ein zentrales Qualitätsmaß für Array-Geometrien. [24, 3]

2.4.3 RÄUMLICHES ALIASING

Räumliches Aliasing tritt auf, wenn der Mikrofonabstand d größer als die halbe Wellenlänge ist ($d > \lambda/2$). Die aliasfreie Maximalfrequenz ergibt sich zu

$$f_{\text{alias}} = \frac{c}{2d},$$

wobei c die Schallgeschwindigkeit ist. Oberhalb dieser Frequenz entstehen sogenannte Grating Lobes, also zusätzliche Nebenkeulen, die die Quellentrennung verfälschen können. [24]

Intuition: Vergleichbar mit einer zu geringen Bildauflösung, bei der feine Strukturen nicht korrekt wiedergegeben werden. Bei Arrays äußert sich dies darin, dass hochfrequente Sprachanteile nicht mehr eindeutig einer Richtung zugeordnet werden können. [29]

Praktisches Beispiel: Beim ReSpeaker-Array (Mikrofonabstand ≈ 8 cm) liegt f_{alias} bei etwa 2.1 kHz [23]. Da Sprachinformationen bis 8 kHz wichtig sind, treten Aliasing-Effekte bereits mitten im Sprachband auf und verschlechtern die Lokalisierung. [29]

2.4.4 GRATING LOBES

Grating Lobes entstehen als zusätzliche Nebenkeulen im Richtdiagramm, wenn der Mikrofonabstand zu groß ist. Sie erscheinen wie „Spiegelbilder“ der Hauptkeule und können ähnlich stark ausgeprägt sein. [13, 24]

Problem: Das Array interpretiert eine Schallquelle fälschlicherweise so, als käme sie aus einer ganz anderen Richtung.

Praktisches Beispiel: In einem Gespräch mit mehreren Sprecher:innen könnten Signale von vorne zusätzlich als virtuelle Quelle von hinten erkannt werden. Dies führt zu Fehlzusweisungen im DoA-Tracking und schwächt die Effektivität des Beamformings. [13]

2.4.5 REVERBERATION (NACHHALL) UND DRR

Nachhall beschreibt die zeitlich ausklingenden Reflexionen eines Schallereignisses im Raum. Ergänzend wird das Verhältnis von Direktschall zu Nachhall (*Direct-to-Reverberant Ratio, DRR*) genutzt. [24]

Praktische Bedeutung: Ein hoher DRR (z. B. >10 dB) bedeutet, dass die Stimme klar und dominant aufgenommen wird. Ein niedriger DRR (z. B. <0 dB) zeigt, dass der Nachhall stärker ist als die Stimme selbst. Dies war insbesondere in Szenario 2 (Mensa) der Fall: Der niedrige DRR erklärt, warum selbst robuste ASR-Modelle dort vermehrt Substitutionen und Deletionen zeigten. [5, 29]

2.4.6 AUTOMATIC SPEECH RECOGNITION (ASR)

Automatic Speech Recognition bezeichnet die Umwandlung von Sprache in Text. Moderne Systeme basieren meist auf neuronalen Sequenzmodellen (z. B. Encoder-Decoder-Architekturen). End-to-End-Modelle wie Whisper koppeln die akustische Verarbeitung direkt an die Sprachmodellierung und zeigen besondere Robustheit gegenüber Rauschen, Akzenten und Übersprechen. [21]

2.4.7 SPEAKER DIARIZATION

Speaker Diarization beantwortet die Frage „Wer hat wann gesprochen?“ und teilt eine Aufnahme in zeitliche Abschnitte mit zugehörigen Sprecherlabels ein. [4]

2.4.7.1 SHORT-TIME FOURIER TRANSFORM (STFT)

Die Kurzzeit-Fourier-Transformation (STFT) zerlegt ein zeitdiskretes Signal in überlappende Segmente und analysiert deren Frequenzinhalte. Dadurch wird eine zeitaufgelöste Darstellung des Spektrums ermöglicht, die zentral für Verfahren wie Wiener-Filter und Beamforming ist. [3]

2.4.7.2 ROOT MEAN SQUARE (RMS)

Der quadratische Mittelwert (RMS) beschreibt die Effektivleistung eines Signals. In der Sprachsignalverarbeitung wird die RMS-Leistung zur robusten Schätzung des Hintergrundrauschens verwendet, indem leisere Signalabschnitte gemittelt werden. [8]

2.4.7.3 DEZIBEL FULL SCALE (DBFS)

dBFS ist ein digitales Pegelmaß, das die Amplitude eines Signals relativ zum maximal darstellbaren Wert (*Full Scale*) eines Systems angibt. 0 dBFS entspricht der höchsten möglichen Aussteuerung, während negative Werte geringere Pegel darstellen. Dieses Maß ist Standard in der digitalen Audiotechnik. [3]

2.4.7.4 MUSICAL NOISE

Als *musical noise* bezeichnet man die tonalen Artefakte, die bei aggressivem spektralem Rauschfiltern auftreten können. Diese Artefakte sind psychoakustisch besonders störend und beeinträchtigen die automatische Spracherkennung oft stärker als das verbleibende Rauschen. [8]

2.4.7.5 OVERLAP-ADD-VERFAHREN

Das Overlap-Add (OLA)-Verfahren dient der effizienten Signalrekonstruktion nach blockweiser Verarbeitung, beispielsweise nach einer STFT. Überlappende Segmente werden nach der Transformation wieder addiert, sodass ein kontinuierliches Ausgangssignal entsteht. [3]

2.4.7.6 KREUZKORRELATION

Die Kreuzkorrelation misst die Ähnlichkeit zweier Signale in Abhängigkeit einer Zeitverschiebung. Sie ist die Grundlage für Verfahren wie SRP-PHAT, da Laufzeitunterschiede zwischen Mikrofonen direkt aus den Peaks der Kreuzkorrelationsfunktion abgeleitet werden können. [7]

2.4.7.7 ALSA (ADVANCED LINUX SOUND ARCHITECTURE)

ALSA ist das Standard-Audiosubsystem unter Linux. Es stellt Treiber, Bibliotheken und Tools für die Audioaufnahme und -wiedergabe bereit. In dieser Arbeit wurde ALSA zur Steuerung des ReSpeaker-Mikrofonarrays und für Mehrkanalaufnahmen mit dem Tool `arecord` genutzt. [22]

2.4.8 HYSTERESE IN SCHWELLWERTVERFAHREN

Unter Hysterese versteht man in der Signalverarbeitung die Verwendung zweier unterschiedlicher Schwellwerte, um instabiles Umschalten (chattering) zu vermeiden. Ein Signal gilt erst dann als *aktiv*, wenn es einen oberen Schwellwert θ_{on} überschreitet. Es bleibt so lange aktiv, bis es unter einen niedrigeren Schwellwert θ_{off} fällt ($\theta_{\text{off}} < \theta_{\text{on}}$). Dieses Zwei-Schwellen-Prinzip verhindert ein häufiges Hin- und Herschalten bei Signalen, die nahe an der Entscheidungsschwelle liegen, und stabilisiert so Verfahren wie Voice Activity Detection oder SNR-basiertes Kanal-Gating. [11]

3 VERWANDTE ARBEITEN

Die im vorherigen Kapitel dargestellten Grundlagen zu Mikrofonarrays, Beamforming und ihrer Integration mit automatischer Spracherkennung verdeutlichen, dass in den letzten Jahren große Fortschritte erzielt wurden. Dennoch bestehen weiterhin zentrale Herausforderungen. Dazu zählen die eingeschränkte Richtwirkung klassischer Verfahren bei tiefen Frequenzen, die begrenzte Robustheit gegenüber variablen Störquellen sowie die komplexe Handhabung von Mehrsprecherszenarien. Hinzu kommt die Frage, wie moderne Deep-Learning-Verfahren sinnvoll mit Mikrofonarray-Frontends kombiniert werden können. Dieses Kapitel stellt Forschungsarbeiten vor, die genau diese Probleme adressieren und entsprechende Lösungsansätze aufzeigen.

3.1 ROBUSTE BEAMFORMING-VERFAHREN

Klassische Verfahren wie das Delay-and-Sum-Beamforming stoßen insbesondere bei realen Einsatzbedingungen schnell an ihre Grenzen, da sie anfällig für Richtungsfehler und Störquellen sind. Um diese Schwächen zu beheben, wurden in den letzten Jahrzehnten robuste adaptive Beamforming-Methoden entwickelt [14]. Hoshuyama et al. [14], präsentierten einen adaptiven Beamformer mit Blockierungsmatrix, der durch den Einsatz von constraints-basierten adaptiven Filtern eine hohe Robustheit gegenüber Richtungsfehlern von bis zu 20 Grad aufweist und dabei eine stabile Unterdrückung von Interferenzen erzielt.

Im Allgemeinen zeigen Studien, dass Beamforming-Frontends Umgebungsgeräusche und Nachhall erheblich reduzieren können. Unter kontrollierten Bedingungen erreichen sie teilweise eine Klangtreue, die mit der von Nahbesprechungsmikrofonen vergleichbar ist [27]. Dies verdeutlicht, dass auch kompakte Arrays in ruhigen Umgebungen eine hohe Sprachqualität liefern können, wenngleich die frequenzabhängige Richtwirkung bei tiefen Frequenzen weiterhin eine Herausforderung darstellt (vgl. Abschnitt 2.1).

Aktuelle Übersichtsarbeiten, zeigen zudem, dass die Forschung zunehmend datengetriebene Methoden integriert. Insbesondere *all-neural Beamformer*, die Signalverarbeitung und Rauschunterdrückung vollständig in neuronale Netze integrieren, markieren einen Paradigmenwechsel von klassischen statistischen Methoden hin zu End-to-End-datengetriebenen Systemen [15]. Solche Ansätze adressieren direkt die im Abschnitt 2.1 beschriebenen Limitierungen der frequenzabhängigen Richtschärfe und versprechen eine robustere Sprachaufnahme in variablen akustischen Szenarien.

3.2 MEHRSPRECHERSZENARIEN UND DISTRIBUTED ARRAYS

Eine weitere Herausforderung, die im Hintergrundkapitel angesprochen wurde, ist die Verarbeitung von Mehrsprechersituationen in lauten Umgebungen, wie sie typischerweise in Konferenzen auftreten. Yoshioka et al. [27], zeigten in ihrem Konzept der „Virtual Microphone Arrays“, dass eine Kombination verteilter Mikrofone eine deutliche Reduktion der Wortfehlerrate (WER) ermöglicht und eine signifikante Verbesserung gegenüber Einkanal-Systemen bietet [27].

Es wurde außerdem gezeigt, dass die Mikrofonanzahl die Wortfehlerrate (WER) maßgeblich beeinflusst. In einer Besprechungsaufgabe führte der Wechsel von einem auf drei Mikrofone zu einer Verringerung der WER um etwa 11 %, während ein Sieben-Mikrofon-Array eine Verbesserung von rund 17 % gegenüber einem Ein-Mikrofon-System erzielte. Diese Ergebnisse belegen, dass eine größere Apertur oder die Nutzung verteilter Mikrofone die Robustheit in Mehrsprecherszenarien deutlich steigert. [27]

Darauf aufbauend präsentierte Kamo et al. [16], im Rahmen der CHiME-8-Challenge ein System, das unabhängig von der genauen Geometrie des Mikrofonarrays operiert und für Multi-Talker-Distant-ASR entwickelt wurde. Ihre Pipeline kombinierte Distributed Arrays mit Beamforming, Sprecherdiarisierung und Whisper-basierten ASR-Modellen. In realistischen Dinnerparty- und Meeting-Szenarien konnte so eine relative Reduktion der WER von 63% gegenüber der Basislinie erzielt werden [16]. Diese

Ergebnisse verdeutlichen, dass gerade in praxisnahen Mehrsprechersituationen die Kombination aus robustem Beamforming und fortgeschrittener ASR essenziell ist.

3.3 INTEGRATION VON MIKROFONARRAYS MIT WHISPER

Neben der reinen Signalverarbeitung stellt die effektive Nutzung von leistungsfähigen ASR-Systemen eine weitere Forschungsperspektive dar. OpenAI's Whisper [21] hat sich als besonders robust gegenüber Rauschen, Akzenten und Übersprechen erwiesen und wird in der Literatur als starkes Backend für Array-basierte Frontends hervorgehoben [25].

Kamo et al. [16], integrierten Whisper erfolgreich in ein verteiltes Mikrofonarray-System, wodurch die genannten Verbesserungen bei Mehrsprecherszenarien erreicht wurden [16]. Neben der Forschung wird die Integration auch in praxisnahen Szenarien erprobt. Busler [6], demonstrierte den Einsatz von Whisper auf Edge-Hardware wie dem Raspberry Pi 5 in Kombination mit einem ReSpeaker Mic Array v2.0. Dabei kamen die integrierten Algorithmen für Beamforming, DoA-Erkennung und Rauschunterdrückung zum Einsatz, um Echtzeit-Transkriptionen lokal zu ermöglichen [6, 23].

Darüber hinaus haben sich Mikrofonarrays auch in industriellen und kommerziellen Anwendungen etabliert. Bereits frühe Einsatzfelder waren Telekonferenzen und Freisprechkommunikation [14, 15]. Heute setzen zahlreiche Smart-Home-Geräte auf integrierte Arrays. Amazon Echo, Google Nest Hub und Apple HomePod verwenden Beamforming, um Benutzerstimmen auch in lauten Umgebungen zuverlässig zu erfassen [19, 15]. Dadurch können Geräte selbst bei Hintergrundgeräuschen oder mehreren gleichzeitig sprechenden Personen Wake-Wörter erkennen, Befehle aus dem gesamten Raum aufnehmen und Sprecher:innen verfolgen oder isolieren [14]. Solche industriellen Beispiele verdeutlichen die praktische Relevanz der Kombination aus Mikrofonarray-Frontends und robusten ASR-Systemen.

Zusammen mit industriellen Beispielen, etwa Amazons Einsatz von Mikrofonarrays in Echo-Geräten zur robusten Sprecherlokalisierung [19], wird deutlich, dass die Kombination aus Beamforming und Whisper sowohl in der Forschung als auch in praktischen Anwendungen eine zentrale Rolle spielt. Damit wird ein Bogen gespannt von den klassischen Problemen (begrenzte Richtwirkung, Störquellenempfindlichkeit) hin zu modernen, hybriden Systemen, die durch Deep Learning und robuste ASR deutliche Fortschritte ermöglichen.

4 METHODIK

Um die in der Problemstellung skizzierten Herausforderungen systematisch zu untersuchen, wird ein experimentelles Vorgehen gewählt. Ziel ist es, die Leistungsfähigkeit eines Mikrofonarrays im Vergleich zu herkömmlichen Aufnahmegeräten zu evaluieren und zu prüfen, inwieweit sich damit qualitativ hochwertige, automatisierte Transkripte von Meetings erzeugen lassen.

Die Methodik umfasst mehrere Schritte. Zunächst wird das eingesetzte Mikrofonsetup beschrieben, das aus einem Mehrkanal-Mikrofonarray sowie zwei Referenzsystemen (Zoom-Mikrofon und Smartphone-Mikrofon) besteht. Anschließend werden die aufgenommenen Audiodaten durch geeignete Signalverarbeitungs- und Beamforming-Verfahren vorverarbeitet, bevor eine automatische Spracherkennung zur Transkripterstellung eingesetzt wird. Schließlich erfolgt eine vergleichende Analyse der Transkriptqualität anhand etablierter Metriken wie der Word Error Rate (WER).

4.1 AUFNAHMEGERÄTE

Für die Untersuchung wurden drei verschiedene Aufnahmesysteme eingesetzt, die unterschiedliche Ansätze zur Sprachaufnahme repräsentieren. Das zentrale Ziel bestand darin, die Leistungsfähigkeit eines kompakten Mikrofonarrays mit zwei etablierten Referenzgeräten zu vergleichen: einem portablen Recorder mit gerichteten Mikrofonen und einem üblichen Smartphone. Diese Auswahl ermöglicht es, sowohl spezialisierte Systeme als auch alltagstaugliche Geräte in die Evaluation einzubeziehen.

4.1.1 MIKROFONARRAY (ReSPEAKER 4-MIC ARRAY v2.0)

Das zentrale Element des Versuchsaufbaus ist ein Mehrkanal-Mikrofonarray, das aus mehreren räumlich angeordneten Mikrofonen besteht. Diese Anordnung ermöglicht die simultane Erfassung von Schall aus verschiedenen Richtungen und erlaubt durch Beamforming-Techniken eine gezielte Fokussierung auf einzelne Sprecher. In dieser Arbeit kommt das ReSpeaker 4-Mic Array v2.0 von Seeed Studio zum Einsatz, das über USB mit einem Raspberry Pi verbunden ist. Die Verbindung erfolgt über das ALSA-Audiosystem, sodass der Raspberry Pi das Array als Mehrkanal-Audiogerät erkennt [6, 23].

Das Array stellt sechs Audiokanäle bereit:

- **Channel 0:** Vorverarbeitetes Monosignal mit integrierten Hardware-Algorithmen (Beamforming, Direction-of-Arrival-Erkennung, Rauschunterdrückung und akustische Echokompensation)
- **Channels 1–4:** Rohdaten der vier kreisförmig angeordneten Mikrofone ohne Vorverarbeitung
- **Channel 5:** Wiedergabekanal (Loopback) [23].

In der Evaluation bezeichnet „ReSpeaker 4-Mic Array (Basis)“ ausschließlich Channel 0 mit den integrierten Hardware-Algorithmen. Die Signalverarbeitungsvarianten mit DoA-Beamforming und Wiener-Filter nutzen dagegen die Rohdaten der Channels 1–4 und führen die Verarbeitung vollständig in Software durch.

Der Ablauf einer Aufnahme ist in Abb. 4.1 dargestellt. Während einer Aufnahme sprechen die Teilnehmenden in das Mikrofonarray, das alle sechs Kanäle simultan erfasst. Die Aufnahme wird über ein eigenes Python-Skript gestartet und als Mehrkanal-WAV-Datei auf dem Raspberry Pi gespeichert. Ein weiteres Skript trennt anschließend die einzelnen Kanäle und speichert sie separat als Einzeldateien. Die weitere Verarbeitung der Aufnahmen erfolgt wie in Abschnitte 4.2 und 4.4 beschrieben.

Mit `pyannote.audio` wird eine Speaker Diarization durchgeführt, die erkennt, wer zu welchem Zeitpunkt gesprochen hat [4]. Mit Whisper werden die Audiodaten transkribiert und anschließend mit den Sprecherlabels kombiniert.




Abbildung 4.1: Schematische Darstellung des Aufnahme- und Verarbeitungsprozesses. Die Teilnehmer:innen sprechen in das Mikrofonarray, das über USB mit dem Raspberry Pi verbunden ist. Der Pi steuert die Aufnahme und speichert die Signale als Mehrkanal-WAV-Datei. Anschließend werden die Kanäle extrahiert und zusammen mit der Originalaufnahme auf einen leistungsstärkeren PC übertragen, wo mittels pyannote.audio die Sprecherdiarisierung und mit Whisper die Transkription durchgeführt werden. Die Ergebnisse werden fusioniert, sodass ein kombiniertes Transkript mit Text und Sprecherlabels entsteht.

4.1.2 ZOOM H4N PRO

Der Zoom H4n Pro ist ein klassisches, gerichtetes Aufnahmesystem mit integrierten X/Y-Stereomikrofonen, die in einem Winkel von 90° oder 120° ausgerichtet werden können. Es ist darauf ausgelegt, Schallquellen aus einer bevorzugten Richtung mit hoher Klarheit einzufangen, während seitliche und weiter entfernte Stimmen deutlich abgeschwächt werden. Mit Abtastraten bis 96 kHz und einer Auflösung bis 24 Bit liefert das Gerät eine hohe Klangtreue bei gleichzeitig geringem Eigenrauschen. [30]

4.1.3 IPHONE 12 MINI

Als drittes Referenzgerät diente ein iPhone 12 mini. Sein integriertes Einzelmikrofon ist für Nahfeldaufnahmen optimiert und liefert in Kombination mit softwareseitigen Algorithmen (z. B. automatische Pegelanpassung, Rauschunterdrückung) eine im Alltagsgebrauch ausreichende Sprachqualität. Aufgrund der fehlenden räumlichen Selektivität ist es jedoch anfälliger für Umgebungsgeräusche und damit weniger geeignet für komplexe Gesprächssituationen. [2]

4.2 RASPBERRY PI

Für die Mehrkanalaufnahmen wurde ein Raspberry Pi 5 als zentrales Aufnahmegerät eingesetzt. Als Betriebssystem kam das aktuelle Raspberry Pi OS (Debian-basiert, 64-bit) zum Einsatz, das die notwendige Unterstützung für USB-Audio und Signalverarbeitung bereitstellt. Der Pi übernahm ausschließlich die Erfassung und Speicherung der Rohdaten des Mikrofonarrays, während rechenintensive Schritte wie Spracherkennung oder Sprechertrennung auf einem leistungsstärkeren PC durchgeführt wurden. Damit fungierte er als dediziertes Aufnahme-Frontend.

Nach der Installation grundlegender Bibliotheken (libasound2-dev, ffmpeg) wurde das ReSpeaker 4-Mic Array v2.0 über USB verbunden. Das Array wurde automatisch als Mehrkanal-Audiogerät erkannt

und konnte über ALSA angesprochen werden. Je nach Firmware standen sowohl ein vorverarbeitetes Monosignal als auch die Rohdaten der vier Mikrofone in bis zu sechs Kanälen zur Verfügung. Die Aufnahmen erfolgten mit dem ALSA-Tool `arecord`. Ein typischer Befehl lautet:

```
arecord -D hw:1,0 -f S16_LE -r 16000 -c 6 meeting.wav
```

Hierbei steht `-D hw:1,0` für das USB-Mikrofonarray, `-f S16_LE` für 16-Bit Little Endian, `-r 16000` für eine Abtastrate von 16 kHz und `-c 6` für die sechs parallelen Audiokanäle. [23]

Zur Automatisierung wurden mehrere Python-Skripte entwickelt:

- `get_index.py` identifiziert die Geräte-ID des Arrays.
- `record.py` startet eine mehrkanalige Aufnahme mit `pyaudio` (16 kHz, 16 Bit, sechs Kanäle) und speichert diese automatisch.
- `channel_split.py` zerlegt die Mehrkanaldatei in separate Spuren pro Mikrofon, was die spätere Analyse und automatische Transkription erleichtert.

Durch diese Automatisierung entfielen manuelle Befehle wie `arecord` oder das händische Aufsplitten der Kanäle mit `ffmpeg`, wodurch die Aufnahmen reproduzierbar und effizient durchgeführt werden konnten.

4.3 VERSUCHSAUFBAU

Um die Leistungsfähigkeit unterschiedlicher Aufnahmegeräte in realistischen Gesprächssituationen zu untersuchen, wurden insgesamt drei Versuche durchgeführt. Dabei wurden gezielt unterschiedliche Umgebungen, Teilnehmerzahlen und Gesprächssituationen gewählt, um ein möglichst breites Spektrum an Bedingungen abzudecken. Alle Versuche wurden mit denselben drei Aufnahmegeräten durchgeführt:

- das ReSpeaker 4-Mic Array v2.0, betrieben über einen Raspberry Pi 5, das gleichzeitig sechs Audiokanäle aufzeichnete (ein vorverarbeitetes Monosignal sowie die Rohdaten der vier Mikrofone und ein Wiedergabekanal),
- das Zoom H4n Pro als Referenzgerät mit zwei gerichteten X/Y-Stereomikrofonen,
- sowie ein iPhone 12 mini mit integriertem omnidirektionalem Mikrofon.

Die Geräte wurden jeweils zentral auf dem Tisch positioniert und vor Beginn der Gespräche nacheinander gestartet, sodass die Aufnahmen zeitlich vergleichbar waren. Durch die parallele Nutzung mehrerer Systeme konnten Unterschiede in der Aufzeichnungsqualität, der Robustheit gegenüber Störgeräuschen und der späteren automatischen Transkription sichtbar gemacht werden. Im Folgenden werden die drei Versuchsanordnungen im Detail beschrieben.

4.3.1 ERSTER VERSUCH

Der erste Versuch simulierte eine typische Vereinssitzung in ruhiger Umgebung. Vier Teilnehmende saßen gleichmäßig verteilt an einem rechteckigen Tisch von etwa zwei Metern Länge, mit Abständen von circa 60 bis 70 cm zueinander. Zusätzlich wurde eine weitere Teilnehmerin online über einen Laptop-Lautsprecher zugeschaltet, um eine realistische hybride Gesprächssituation nachzustellen. Der Laptop befand sich ebenfalls auf dem Tisch, sodass alle Aufnahmegeräte ihre Stimme wie die der physisch Anwesenden erfassen konnten. Als Gesprächsthema diente eine Vorstandssitzung eines Tennisvereins, in deren Rahmen organisatorische Fragen (z. B. Rollen der Vorstandsmitglieder:innen oder die Anschaffung einer Flutlichtanlage) diskutiert wurden. Die Aufnahme dauerte etwa zehn Minuten.

4.3.2 ZWEITER VERSUCH

Der zweite Versuch wurde in der Mensa der Universität durchgeführt, um eine Aufnahmeumgebung mit hohem Störgeräuschpegel zu simulieren. Vier Personen nahmen an einem Tisch Platz, jeweils zwei

saßen sich gegenüber. Die Abstände zwischen den Sprecher:innen betrugen etwa 60 bis 80 cm. Die Gesprächssituation bestand darin, dass eine Person die Rolle des Fragenden übernahm, während die anderen drei nacheinander ihre Bachelorarbeitsthemen vorstellten. Ziel war es, in einer lauten Umgebung ein Interview zu führen, in dem möglichst viele Fachbegriffe fallen, um die Spracherkennung gezielt herauszufordern. Die Gesprächsdauer betrug etwa sechs Minuten.

4.3.3 DRITTER VERSUCH

Auch der dritte Versuch fand in der Mensa statt, jedoch mit erweiterter Teilnehmerzahl. Sechs Personen saßen an einem größeren Tisch, der bewusst doppelt so lang wie im zweiten Versuch gewählt wurde. Dadurch betrugen die Abstände zwischen den Teilnehmenden mindestens einen Meter. Die zentrale Positionierung der Aufnahmegeräte führte dazu, dass einige Sprecher:innen nur etwa 50 cm, andere hingegen über einen Meter von den Mikrofonen entfernt waren. Das Gesprächsthema war bewusst einfach gehalten, um spontane und kurze Beiträge aller Teilnehmenden zu fördern. Jede Person sollte einen Vorteil und einen Nachteil der Universität Bonn nennen. Die Aufnahmedauer betrug etwa sechs Minuten. Ziel war es, die Robustheit der Systeme bei größerer Sprecherzahl, ungleichen Abständen und starkem Hintergrundgeräusch zu überprüfen.

4.4 COMPUTER UND VERARBEITUNGSPipeline

Die rechenintensive Nachbearbeitung erfolgte auf einem Desktop-PC mit folgender Spezifikation: AMD Ryzen 7500F, 32 GB RAM und einer RTX 4070 Super für die Whisper-Inferenz. Um die fehlende Rechenleistung des Raspberry Pi auszugleichen und zugleich die Bedingungen eines leistungsstarken Servers zu simulieren, wurde bewusst ein möglichst rechenstarker Computer gewählt. Die Verarbeitung gliederte sich in mehrere Schritte:

Zunächst wurden die vom Raspberry Pi übertragenen Mehrkanal-WAV-Dateien eingelesen und die beschriebenen Signalverarbeitungsalgorithmen angewandt. Die resultierenden Audio-Streams wurden dann parallel zwei verschiedenen Erkennungssystemen zugeführt:

- **OpenAI Whisper (large-v3)**: übernahm die automatische Spracherkennung mit folgenden Parametern:
 - `language=None`: Automatische Spracherkennung (primär Deutsch erwartet)
 - `verbose=False`: Keine Zwischenausgaben während der Verarbeitung
 - `word_timestamps=False`: Zeitstempel nur auf Segment-Ebene
- **pyannote.audio 3.1**: führte die Speaker Diarization mit der Pipeline `pyannote/speaker-diarization` durch, wobei die Standardparameter verwendet wurden. Das System erkennt automatisch die Anzahl der Sprecher und segmentiert die Aufnahme in zeitliche Abschnitte mit zugehörigen Sprecherlabels.
- **Synchronisation**: Simultanes manuelles Starten aller drei Aufnahmegeräte
- **Signalverarbeitung**: Alle Parameter in den Verarbeitungsskripten fest kodiert:
 - Rahmenlänge: 40 ms bei 10 ms Schrittweite
 - SNR-Schwelle: 3 dB (vgl. Kapitel 2.2.1)
 - DoA-Konfidenz: 0,2 (vgl. Kapitel 2.2.3)
 - Glättungsfaktor DoA: $\alpha = 0,9$
- **Audioformat**: Einheitlich 16 kHz, 16-Bit, Peak-Normalisierung auf 98%

Die Fusion beider Ergebnisse erfolgte über ein zeitbasiertes Alignment. Für jeden von Whisper erkannten Textabschnitt wurde der entsprechende Zeitbereich in der Diarisierung gesucht und das dominante Sprecherlabel zugeordnet. Bei zeitlichen Überlappungen wurde das Sprecherlabel mit der längsten Überschneidung gewählt. Zusammenhängende Äußerungen desselben Sprechers wurden bei Pausen unter 0,75 Sekunden automatisch zu einem Segment zusammengefasst, um eine natürlichere Transkriptstruktur zu erzeugen.

4.5 NACHBEARBEITUNG DURCH SNR-BASIERTES GATING MIT WIENER-POSTFILTER

Der entwickelte Algorithmus dient zur Verbesserung von Sprachaufnahmen aus Mehrkanal-Mikrofonsystemen. Ziel ist es, durch ein signalbasiertes Auswahlverfahren Störgeräusche zu unterdrücken und die Sprachverständlichkeit zu erhöhen. Der Kernansatz kombiniert ein SNR-basiertes Kanal-Gating mit einem anschließenden milden Wiener-Filter. [3, 24]

Im ersten Schritt werden die Audiosignale mehrerer Mikrofone geladen, auf gleiche Länge gebracht und pegelnormalisiert. Anschließend erfolgt eine Rahmenbildung der Signale mit einer Fensterlänge von 40 ms und einer Schrittweite von 10 ms. Für jeden Kanal und jedes Frame wird sowohl der Pegel in dBFS als auch eine Rauschschätzung bestimmt. Letztere basiert auf der RMS-Leistung der leisesten 20 % der Frames, was eine robuste Schätzung des Hintergrundrauschens ermöglicht. Auf dieser Grundlage wird das SNR (vgl. Kapitel 2.2.1) pro Kanal und Frame berechnet. [8]

Das eigentliche SNR-Gating wählt pro Zeitschritt den Kanal mit dem höchsten SNR als Hauptquelle aus. Ist ein zweiter Kanal nur geringfügig schwächer (innerhalb von 2 dB), wird er ebenfalls berücksichtigt, um Überschneidungen und Sprecherwechsel möglichst konsistent abzubilden. Eine Hysterese mit Haltezeit (Release Frames) verhindert dabei ein zu häufiges Umschalten zwischen Kanälen, wodurch die Stabilität des resultierenden Signals erhöht wird. Die gewählten Frames werden anschließend über ein Overlap-Add-Verfahren rekonstruiert. [3]

Zur weiteren Verbesserung der Signalqualität wird ein zweistufiges Postprocessing angewandt:

1. Ein Hochpassfilter ($f_c = 80$ Hz, Ordnung 2) entfernt tieffrequente Störungen und reduziert dumpfe Anteile.
2. Ein milder Wiener-Postfilter auf Basis einer Kurzzeit-Fourier-Transformation (STFT) (vgl. Kapitel 2.4.7.1) unterdrückt spektrale Rauschanteile. Die STFT-Parameter umfassen eine Fensterlänge von 640 Samples mit 480 Samples Überlappung (75%). Das Rauschleistungsdichtespektrum wird analog zur initialen Rauschschätzung aus den leisesten 20% der Frames bestimmt. Die spektrale Verstärkungsfunktion $G(f)$ wird nach dem klassischen Wiener-Ansatz berechnet:

$$G(f) = \sqrt{\frac{\text{SNR}(f)}{\text{SNR}(f) + 1}} \quad (4.1)$$

wobei $\text{SNR}(f) = S(f)/N(f)$ das frequenzabhängige Signal-Rausch-Verhältnis bezeichnet. Um musical noise zu vermeiden, wird die Verstärkungsfunktion nach unten auf -12 dB begrenzt ($G_{\min} = 10^{-12/20} \approx 0.251$). Diese konservative Parametrisierung verhindert eine zu aggressive Rauschunterdrückung und erhält die Sprachverständlichkeit. [8, 15]

Abschließend wird das resultierende Signal peak-normalisiert, sodass die Aussteuerung konsistent auf einen Zielwert (0.98) gebracht wird. Das finale Ausgangssignal vereint somit die Vorteile einer adaptiven Mikrofonkanal-Auswahl mit einer frequenzselektiven Rauschunterdrückung.

Insgesamt stellt der Algorithmus eine praxisorientierte Lösung für Mehrkanalaufnahmen dar, die insbesondere in realistischen Umgebungen mit variabler Sprecherpositionierung und Störgeräuschen eine deutliche Verbesserung der Sprachqualität erlaubt. Ähnliche Verfahren, die auf SNR-basiertem Beamforming und spektralen Postfiltern beruhen, sind auch in der Literatur etabliert. [8, 15]

4.5.1 ERWEITERUNG DURCH DOA-BASIERTES BEAMFORMING

Das SNR-basierte Kanal-Gating nutzt ausschließlich die Signalqualität der einzelnen Mikrofone. In komplexeren Szenarien mit mehreren Sprechern oder starkem Nachhall reicht diese Information jedoch nicht aus. Hier bietet die räumliche Verarbeitung durch DoA-basiertes Beamforming einen zusätzlichen

Ansatz: Anstatt nur den besten Kanal auszuwählen, werden alle Mikrofonsignale kohärent kombiniert, um eine dominante Schallquelle gezielt zu verstärken. [24, 15, 8]

Grundprinzip und Limitierungen Das ReSpeaker-Array besteht aus vier kreisförmig angeordneten Mikrofonen mit einem Abstand von etwa 8 cm [23]. Dies führt zu einer alias-freien Maximalfrequenz von ca. 2,137 kHz ($f_{\text{alias}} = c/(2d)$ mit $c = 343$ m/s bei 20°C und $d = 0,08$ m). Da Sprache wichtige Komponenten bis 8 kHz enthält, treten bereits im mittleren Sprachband Aliasing-Effekte auf, die die Richtungsschätzung beeinträchtigen können [14].

Für die DoA-Schätzung wird das etablierte SRP-PHAT-Verfahren (vgl. Kapitel 2.2.4) eingesetzt [10]. Es basiert auf Kreuzkorrelationen im Frequenzbereich, wobei die Phaseninformation stärker gewichtet wird als die Amplitude. Dies reduziert den Einfluss von Nachhall und Pegelunterschieden.

Die gewichtete Kreuzkorrelation zweier Mikrofone m und n wird wie folgt definiert:

$$R_{mn}(f, k) = \frac{X_m(f, k) X_n^*(f, k)}{|X_m(f, k) X_n^*(f, k)| + \varepsilon} \quad (4.2)$$

Hierbei beschreibt $X_m(f, k)$ das STFT-Spektrum (vgl. Kapitel 2.4.7.1) des Mikrofons m im Frequenzbin f und Frame k , wobei das Sternsymbol die komplexe Konjugation kennzeichnet. Der Parameter ε ist ein kleiner Regularisierungsterm (typischerweise 10^{-10}) zur Vermeidung numerischer Instabilität bei Division durch Null. Durch die Normierung bleibt nur die relative Phaseninformation erhalten, was die Robustheit erhöht.

Für jeden Testwinkel θ aus dem Suchbereich $\Theta = \{-90^\circ, -89^\circ, \dots, +90^\circ\}$ wird die *Steered Response Power* berechnet:

$$S(\theta, k) = \sum_f \sum_{m < n} \Re \left\{ R_{mn}(f, k) e^{j2\pi f(\tau_m(\theta) - \tau_n(\theta))} \right\} \quad (4.3)$$

wobei $\tau_m(\theta)$ die lauffzeitbedingte Verzögerung des Mikrofons m für eine Schallquelle aus Richtung θ beschreibt. Das Symbol $\Re$ bezeichnet den Realteil der komplexen Größe. Die Frequenzsummutation erstreckt sich über alle nutzbaren Frequenzbins der STFT (typischerweise 0–8 kHz bei einer Abtastrate von 16 kHz). Das Maximum von $S(\theta, k)$ markiert die wahrscheinlichste Einfallsrichtung. [3, 13, 29]

Stabilisierung und Konfidenzgating Die DoA-Schätzung neigt in der Praxis zu starken Schwankungen. Zwei Maßnahmen stabilisieren das Verfahren:

Exponentielle Glättung: Der geschätzte Winkel wird über mehrere Frames gemittelt:

$$\sim\theta_k = \alpha \cdot \sim\theta_{k-1} + (1 - \alpha) \cdot \hat{\theta}_k, \quad \alpha = 0.9 \quad (4.4)$$

wobei $\hat{\theta}_k$ die aktuelle Schätzung und $\sim\theta_k$ der geglättete Wert ist. Der initiale Wert $\sim\theta_0$ wird auf die erste robuste Schätzung gesetzt (typischerweise der erste Frame mit $\gamma_k \geq 0.2$). Ein hoher Glättungsfaktor α unterdrückt Ausreißer, erlaubt aber dennoch die Erfassung von Sprecherwechseln.

Konfidenzgating: Ein Konfidenzmaß γ_k bewertet, wie deutlich sich das Maximum von $S(\theta, k)$ von den restlichen Winkeln abhebt:

$$\gamma_k = \frac{\max_{\theta} S(\theta, k) - \text{mean}_{\theta} S(\theta, k)}{\text{std}_{\theta} S(\theta, k)} \quad (4.5)$$

Nur Frames mit $\gamma_k \geq 0.2$ werden für das Beamforming verwendet, um instabile Schätzungen zu vermeiden. Die gewählten Parameter ($\alpha = 0.9$, $\gamma = 0.2$) stellen einen Kompromiss zwischen Stabilität und Adaptivität dar. [3]

Delay-and-Sum-Beamforming Basierend auf der stabilisierten DoA-Schätzung $\sim\theta_k$ werden die Mikrofonsignale so verzögert, dass sie für die Zielrichtung konstruktiv interferieren:

$$Y(f, k) = \frac{1}{C} \sum_{m=1}^C X_m(f, k) e^{-j2\pi f \tau_m(\sim\theta_k)} \quad (4.6)$$

mit C als Anzahl der Mikrofone. Durch die kohärente Addition verstärken sich Signale aus der Zielrichtung, während Störquellen aus anderen Richtungen abgeschwächt werden. Das kombinierte Spektrum $Y(f, k)$ wird anschließend per Inverse-STFT zurück in den Zeitbereich transformiert. Frames mit geringer Konfidenz werden dabei übersprungen, um Artefakte zu vermeiden. [3, 13, 29]

Integration in die Signalverarbeitungskette Das DoA-basierte Beamforming ergänzt das SNR-Gating als alternative Verarbeitungsmethode. Beide Ansätze werden in der Evaluation separat getestet:

- **SNR-Gating:** Adaptive Kanalauswahl, robust bei diffusen Störgeräuschen
- **DoA-Beamforming:** Kohärente Signalkombination, vorteilhaft bei klar lokalisierbaren Quellen

Beide Verfahren nutzen identische Nachverarbeitungsschritte (Hochpassfilter bei 80 Hz und Wiener-Postfilter) für eine faire Vergleichbarkeit.

	c	Schallgeschwindigkeit [m/s]
	d	Mikrofonabstand [m]
	f	Frequenz [Hz]
	θ	Azimutwinkel [°]
	$\tau_m(\theta)$	Laufzeitverzögerung von Mikrofon m [s]
	γ_k	Konfidenzmaß (dimensionslos)
	ε	Regularisierungsparameter
Symbolverzeichnis für DoA-Verfahren		




Abbildung 4.2: Schematische Darstellung eines Delay-and-Sum-Beamformers. Die Mikrofonsignale $x_m[n]$ werden entsprechend der laufzeitbedingten Verzögerung $\tau_m(\theta)$ verschoben, gewichtet und anschließend summiert, um das Ausgangssignal $y[n]$ zu erzeugen. Der Pfeil $u(\theta)$ kennzeichnet dabei die Einfallsrichtung der ebenen Welle, aus der das Signal auf das Array trifft.

4.6 PARAMETEROPTIMIERUNG UND KALIBRIERUNG

Die in den Algorithmen verwendeten Parameter wurden durch systematisches Testen verschiedener Konfigurationen optimiert. Dabei stand die Minimierung der WER als Zielgröße im Vordergrund, wobei gleichzeitig die Stabilität des Systems über verschiedene akustische Bedingungen hinweg berücksichtigt wurde.

4.6.1 SNR-GATING PARAMETER

Für das SNR-basierte Kanal-Gating wurden folgende Parameter experimentell bestimmt:

- Rahmenlänge: 40 ms bei einer Schrittweite von 10 ms erwies sich als optimaler Kompromiss zwischen zeitlicher Auflösung und statistischer Robustheit der SNR-Schätzung
- Mindest-dBFS-Schwellwert: -48 dB als Voice Activity Detection-Schwelle, um Hintergrundrauschen von Sprachaktivität zu unterscheiden
- SNR-Mindestanforderung: 3 dB als untere Grenze für die Kanalauswahl
- Hysteresis-Parameter (vgl. Kapitel 2.4.8): 4 Release-Frames und 2 dB Toleranz für Zwei-Kanal-Mischung zur Vermeidung von Umschaltartefakten

Die Rauschschätzung erfolgt über die leisesten 20% der Frames pro Kanal, was sich als robust gegenüber gelegentlichen Sprechpausen erwies.

4.6.2 DOA-BEAMFORMING PARAMETER

Die DoA-Schätzung mittels SRP-PHAT (vgl. Kapitel 2.2.4) nutzt folgende optimierte Einstellungen:

- Azimut-Suchbereich: 360° in 1°-Schritten für das kreiförmige Array
- Exponentieller Glättungsfaktor: $\alpha = 0,9$ für die zeitliche Stabilisierung der Winkelschätzung
- Konfidenz-Schwellwert: 0.2 als Mindestkriterium für die Aktivierung des Delay-and-Sum-Beamformers
- STFT-Parameter: 640 Samples Fensterlänge mit 75% Überlappung (480 Samples)

Der Glättungsfaktor von 0.9 wurde gewählt, um schnelle Sprecherwechsel zu erfassen, während gleichzeitig Schätzrauschen unterdrückt wird. Ein niedrigerer Wert (z. B. 0.7) führte zu instabilen Winkelverfolgungen, während höhere Werte (z. B. 0.95) zu träge auf tatsächliche Sprecherwechsel reagierten.

4.6.3 KALIBRIERUNG UND NORMALISIERUNG

Zur Gewährleistung der Vergleichbarkeit zwischen den Aufnahmesystemen wurden folgende Kalibrierungsschritte durchgeführt:

- Peak-Normalisierung: Alle Eingangssignale wurden auf 98% des Maximalwerts normalisiert, um Übersteuerungen zu vermeiden
- Kanalausrichtung: Die vier Mikrofonkanäle des ReSpeaker-Arrays wurden zeitlich synchronisiert (Hardware-bedingt bereits gegeben)
- Positionskalibrierung: Die Mikrofon-Positionen wurden vermessen und als Eingabe für die DoA-Berechnung verwendet. Bei einem kreisförmigen Array mit Radius 5,66 cm ergeben sich folgende kartesische Koordinaten relativ zum Zentrum:
 - Mikrofon 1 (0°): (5,66 cm, 0 cm)
 - Mikrofon 2 (90°): (0 cm, 5,66 cm)
 - Mikrofon 3 (180°): (-5,66 cm, 0 cm)
 - Mikrofon 4 (270°): (0 cm, -5,66 cm)

Der Abstand zwischen benachbarten Mikrofonen beträgt ca. 8 cm.

Verifikation der Mikrofonpositionierung: Da die korrekte Zuordnung der Mikrofonkanäle zu den physikalischen Positionen für die DoA-Schätzung kritisch ist, wurde eine systematische Kalibrierung durchgeführt. Zunächst wurden die Mikrofon-Positionen des Mikrofonarrays physikalisch vermessen und als kreisförmige Anordnung mit Radius 5,66 cm dokumentiert (siehe oben). Anschließend wurde die Kanalzuordnung durch gezielte Kalibrierungsaufnahmen verifiziert. Ein bekanntes Testsignal (Klatschen) wurde aus definierten Richtungen (0° , 45° , 90° , 135° , 180° , 225° , 270° , 315°) eingespielt und die entsprechende DoA-Schätzung überprüft. Die Ergebnisse bestätigten, dass die Dateien `uni_ch1_mic*.wav` bis `uni_ch4_mic*.wav` korrekt den Positionen entsprechen und die im Code hinterlegten Koordinaten `MIC_POS` mit der tatsächlichen Hardware-Anordnung übereinstimmen. Diese Verifikation war essenziell, da eine falsche Kanalzuordnung die gesamte räumliche Signalverarbeitung verfälschen würde.

4.6.4 OPTIMIERUNGSPROZESS

Die Parameteroptimierung erfolgte iterativ anhand der Aufnahmen aus Versuch 1 (ruhige Umgebung). Dabei wurden zunächst die SNR-Gating-Parameter variiert, bis eine stabile Sprachaktivitätserkennung erreicht wurde. Anschließend wurden die DoA-Parameter so angepasst, dass die Lokalisierung robust funktionierte. Ziel war es, einen Parametersatz zu entwickeln, der nicht nur für die Optimierungsumgebung, sondern auch für andere akustische Bedingungen geeignet ist.




Abbildung 4.3: Systematische Parameteroptimierung für SNR-Gating (a), DoA-Beamforming (b) und exponentielle Glättung (c).

Zur Validierung der Robustheit wurden für alle drei Szenarien systematische Parameterexperimente durchgeführt. Dabei zeigte sich, dass die für Szenario 1 optimierte Konfiguration auch in den komplexeren akustischen Umgebungen (Szenarien 2 und 3) konsistent die besten Ergebnisse lieferte (vgl. Abbildung ??). Diese Konsistenz über verschiedene akustische Bedingungen hinweg bestätigt, dass die gewählten Parameter eine robuste Balance zwischen Anpassungsfähigkeit und Stabilität bieten. Die empirische Validierung untermauert, dass ein einheitlicher Parametersatz für verschiedene Aufnahmesituationen praktikabel ist, ohne dass szenario-spezifische Nachkalibrierung erforderlich wird.

4.7 EVALUATIONSMETHODIK

Die Evaluation konzentriert sich auf die Frage, inwiefern die verschiedenen Systeme qualitative Transkripte ermöglichen. Neben der reinen Worterkennungsrate ist dabei insbesondere relevant, ob Sprecher korrekt unterschieden und ihre Äußerungen konsistent zugeordnet werden können.

Zur Bewertung kommen daher zwei zentrale Metriken zum Einsatz. Die klassische Word Error Rate (WER) dient der Messung der lexikalischen Genauigkeit der Transkriptionen[1], während der Speaker-Attributed Recall (SA-Recall) zusätzlich die korrekte Sprecherzuordnung berücksichtigt[28]. Durch diese Kombination lassen sich sowohl Unterschiede in der Erkennungsleistung der Geräte als auch die Robustheit der eingesetzten Spracherkennungssysteme bei komplexen Gesprächssituationen nachvollziehbar erfassen.

4.7.1 REFERENZTRANSKRIPTE

Zur Bewertung der automatisch generierten Transkripte wurden manuelle Referenztranskripte erstellt, die als Ground Truth für die WER- und SA-Recall-Berechnung dienten. Eine Person transkribierte zunächst alle Aufnahmen durch mehrfaches Anhören und erstellte zeitgestempelte Transkripte im gleichen Format wie die automatische Pipeline (Whisper + pyannote.audio). Dabei wurden sowohl der gesprochene Text als auch die Sprecherzuordnungen manuell annotiert. Anschließend durchliefen diese Referenztranskripte einen mehrstufigen Korrekturprozess. Mehrere Personen überprüften die Transkripte sowohl durch erneutes Anhören der Audiodateien als auch durch Textvergleich auf lexikalische und attributionale Fehler. Dieser Prozess stellte sicher, dass die Ground Truth eine hohe Qualität aufweist und als verlässliche Bewertungsgrundlage für die automatischen Systeme dient.

4.7.2 WORD ERROR RATE (WER)

Die *Word Error Rate* (WER) ist eine etablierte Metrik zur Bewertung der Genauigkeit automatischer Spracherkennungssysteme (Automatic Speech Recognition, ASR). Sie beschreibt, wie stark ein automatisch erzeugtes Transkript von einer fehlerfreien Referenztranskription abweicht. Die Berechnung erfolgt durch den Abgleich der Wortfolgen und unterscheidet drei Arten von Fehlern:

- **Substitutionen (S):** Ein Wort im Referenztext wird durch ein falsches Wort ersetzt.
- **Deletionen (D):** Ein Wort aus der Referenz fehlt im Hypothesentext.
- **Insertionen (I):** Ein zusätzliches Wort erscheint im Hypothesentext, das in der Referenz nicht vorkommt. [1]

Die Gesamtzahl der Wörter in der Referenz wird mit N bezeichnet. Die WER ergibt sich damit zu:

$$\text{WER} = \frac{S + D + I}{N} \quad (4.7)$$

Die WER wird als Verhältnis von Fehlern zur Gesamtanzahl der Wörter angegeben. Je niedriger der Wert, desto höher ist die Transkriptionsgenauigkeit. In der Praxis dient die WER als zentrale Kennzahl zur vergleichenden Evaluation verschiedener Spracherkennungssysteme, Mikrofonsetups oder Vorverarbeitungsmethoden. Sie ermöglicht es, die Robustheit eines Systems gegenüber Störgeräuschen, Sprecherüberlappungen oder variierenden Stimmen quantitativ zu erfassen. [1]

Es ist jedoch zu beachten, dass die WER ausschließlich auf Wortebene arbeitet und semantische oder syntaktische Aspekte unberücksichtigt lässt. Daher wird sie in vielen Studien durch ergänzende Metriken wie Recall oder die Speaker-Attribution-Accuracy ergänzt, um ein vollständigeres Bild der Systemleistung zu erhalten. [1]

4.7.3 SPEAKER-ATTRIBUTED RECALL (SA-RECALL)

Die *Speaker-Attributed Recall* (SA-Recall) ergänzt die *Speaker-Attributed Word Error Rate* (SA-WER) um eine komplementäre Sichtweise. Während die SA-WER den Anteil an Fehlern quantifiziert, indem sowohl lexikalische Fehler (Substitutionen, Insertionen, Deletionen) als auch Fehler bei der Sprecherzuordnung in die Berechnung eingehen [20], misst der SA-Recall stattdessen den Anteil der korrekt erkannten *und* gleichzeitig richtig attribuierten Wörter [28, 17].

Formale Definition:

$$\text{SA-Recall} = \frac{C_{sa}}{N} \quad (4.8)$$

Dabei bezeichnen:

- C_{sa} = Anzahl der Wörter, die sowohl lexikalisch korrekt erkannt als auch dem richtigen Sprecher zugeordnet wurden,
- N = Gesamtzahl der Wörter in der Referenz. [17, 28]

Berechnungsverfahren: Die Berechnung erfolgt zweistufig. Zunächst wird mittels Dynamic Programming ein optimales Alignment zwischen Referenz- und Hypothesenwörtern erstellt (sprecherunabhängig). Anschließend wird für jedes korrekt alignierte Wortpaar überprüft, ob auch die Sprecherzuordnung übereinstimmt (case-insensitive Vergleich). Nur Wörter, die beide Kriterien erfüllen, tragen zu C_{sa} bei. [17, 28]

Interpretation: Der SA-Recall liegt stets im Intervall $[0, 1]$ und ist per Definition kleiner oder gleich dem klassischen Recall, da zusätzlich zur lexikalischen Korrektheit auch die Sprecherattribution stimmen muss. Ein Wert von 0,8 bedeutet, dass 80% aller Referenzwörter sowohl korrekt transkribiert als auch dem richtigen Sprecher zugeordnet wurden. [17, 28]

5 EVALUATION

Dieses Kapitel bewertet die Leistungsfähigkeit des ReSpeaker 4-Mic Arrays im Vergleich zu Zoom H4n Pro und iPhone 12 mini über drei realistische Szenarien. Als Kenngrößen dienen die WER für die lexikalische Genauigkeit sowie der Speaker-Attributed Recall (SA-Recall) für korrekt erkannte korrekt attribuierte Wörter (vgl. Kap. 4.7). Die Darstellung erfolgt zweistufig:

- (i) pro Szenario eine knappe Ergebniszusammenfassung mit Tabelle
- (ii) eine interpretierende Auswertung mit Bezug zu den Forschungsfragen und den in Kap. 2 diskutierten akustischen Effekten.

5.1 VERSUCH 1

Kernaussagen: In der ruhigen Besprechungssituation liefert das Array nach Verarbeitung die besten Ergebnisse. Tabelle 5.1 zeigt:

- (i) DoA-Beamforming minimiert die WER
- (ii) Wiener-Filter maximiert den SA-Recall
- (iii) DoA-Beamforming hat den stärksten Effekt auf die WER. Die Einzelgeräte (iPhone, Zoom) bleiben solide, profitieren aber weniger von Post-Filtering.

System / Methode	WER [%]	SA-Recall [%]
ReSpeaker 4-Mic Array (Basis, Channel 0)	37.0	77.2
ReSpeaker + DoA-Beamforming	24.6	79.5
ReSpeaker + Wiener-Filter	26.6	81.5
ReSpeaker + DoA + Wiener-Filter	27.8	82.1
iPhone 12 mini	29.2	80.4
iPhone 12 mini + Wiener-Filter	33.04	80.61
Zoom H4n Pro	31.4	80.7
Zoom H4n Pro + Wiener-Filter	27.17	82.72

Tabelle 5.1: Vergleich der WER und des SA-Recall verschiedener Aufnahmesysteme und Signalverarbeitungsmethoden im ersten Aufnahmeszenario.

5.1.1 AUSWERTUNG VERSUCH 1

Die Ergebnisse des ersten Szenarios (vgl. Tabelle 5.1) verdeutlichen, dass das rohe Ausgangssignal des ReSpeaker-Arrays ohne Nachverarbeitung den Referenzsystemen zunächst unterlegen ist. Mit einer WER von 37.0 % und einem SA-Recall von 77.2 % zeigt sich, dass die omnidirektionale Mikrofoncharakteristik zwar eine breite Raumerfassung erlaubt, gleichzeitig jedoch ein relativ geringes Signal-Rausch-Verhältnis erzeugt. Dies begünstigt Substitutionen und Deletionen in der Transkription und erschwert eine konsistente Sprecherzuordnung.

Die Anwendung des Wiener-Filters führt zu einer deutlichen Verbesserung sowohl des WER (26.6 %) und des SA-Recall (81.5 %). Dies bestätigt, dass frequenzselektive Rauschunterdrückung insbesondere diffuse Hintergrundanteile wirkungsvoll kompensiert und so die spektrale Klarheit des Sprachsignals erhöht. Auffällig ist, dass diese Verbesserung weniger die lexikalische Erkennung (WER) als vielmehr die Stabilität der Sprechersegmente (SA-Recall) unterstützt.

Das DoA-basierte Beamforming liefert mit einer WER von 24.6 % den besten Gesamtwert. Durch die laufzeitbasierte Ausrichtung auf eine dominante Quelle wird die Zielstimme kohärent verstärkt, während räumlich anders lokalisierte Störsignale abgeschwächt werden. Interessanterweise bleibt der Zugewinn beim SA-Recall mit 79.5 % vergleichsweise moderat, was darauf hindeutet, dass die Qualität der Sprecherattribution weniger von der Signalverstärkung als vielmehr von der diarization- und ASR-Komponente bestimmt wird.

Im Vergleich dazu erzielen die Referenzgeräte iPhone 12 mini und Zoom H4n Pro solide Werte (29–31 % WER, ca. 80 % SA-Recall), profitieren jedoch nicht von signaladaptiven Verbesserungen. Zwar steigert ein nachträglicher Wiener-Filter die WER teilweise (z. B. Zoom: 27.2 %), dennoch bleibt die Leistung hinter dem adaptiven Array-Ansatz zurück.

Zusammenfassend zeigt Versuch 1, dass das Mikrofonarray durch geeignete Nachbearbeitung nicht nur mit klassischen Geräten konkurrieren kann, sondern diese sogar übertrifft. Besonders die Kombination aus spektraler (Wiener-Filter) und räumlicher Signalverarbeitung (DoA-Beamforming) erweist sich als Schlüssel zur Verbesserung der Transkriptionsqualität in ruhigen Gesprächssituationen.

5.2 VERSUCH 2

Kernaussagen: In der Mensa (diffuses Störfeld) schwächen die Verarbeitungsalgorithmen ab. Tabelle 5.2 zeigt:

- (i) DoA-Beamforming senkt die WER nur noch leicht (1.8 %),
- (ii) der Wiener-Filter allein ist in der lauten, nichtstationären Umgebung klar schwächer (niedriger SA-Recall),
- (iii) Referenzgeräte bleiben stabil, profitieren aber gar nicht vom Post-Filtering.

System / Methode	WER [%]	SA-Recall [%]
ReSpeaker 4-Mic Array (Basis, Channel 0)	28.8	79.3
ReSpeaker + DoA-Beamforming	27.0	78.6
ReSpeaker + Wiener-Filter	31.9	71.8
ReSpeaker + DoA + Wiener-Filter	27.9	79.1
iPhone 12 mini	24.5	77.9
iPhone 12 mini + Wiener-Filter	26.29	77.67
Zoom H4n Pro	27.5	77.8
Zoom H4n Pro + Wiener-Filter	33.85	73.35

Tabelle 5.2: Vergleich der WER und des SA-Recall verschiedener Aufnahmesysteme und Signalverarbeitungsmethoden im zweiten Aufnahmeszenario.

5.2.1 AUSWERTUNG VERSUCH 2

Die Ergebnisse des zweiten Szenarios (vgl. Tabelle. 5.2) verdeutlichen die erhöhte Herausforderung einer lauten Umgebung mit diffusem Hintergrundgeräusch. Das ReSpeaker-Array erreicht in der Basisversion 28,8 % WER und 79,3 % SA-Recall und bleibt damit grundsätzlich konkurrenzfähig. Durch DoA-Beamforming verbessert sich die WER leicht auf 27,0 %, während der SA-Recall mit 78,6 % nahezu konstant bleibt. Dies deutet darauf hin, dass die Richtschätzung auch in akustisch komplexen Räumen eine gewisse Robustheit besitzt, jedoch nur begrenzten Zugewinn bringt.

Der Wiener-Filter allein erweist sich hingegen als wenig effektiv (31.9 % WER, 71.8 % SA-Recall). Obwohl er spektrale Störanteile reduziert, gelingt es ihm nicht, die stark variablen und nichtstationären Störquellen einer Mensa-Situation zuverlässig zu unterdrücken. Auch die Kombination von DoA-Beamforming und Wiener-Filter liefert keine wesentliche Verbesserung über die Einzelverfahren hinaus

(27.9 % WER, 79.1 % SA-Recall).

Ein Vergleich mit den Referenzgeräten zeigt, dass insbesondere das iPhone 12 mini mit 24,5 % WER und 77.9 % SA-Recall leicht bessere Ergebnisse erzielt. Nachträgliche Filterung bringt hier kaum Vorteile. Beim Zoom H4n Pro sinkt die WER von 27.5 % auf 26.3 %, während der SA-Recall nahezu unverändert bleibt.

Insgesamt bestätigt Versuch 2, dass für Mikrofonarrays in akustisch komplexen Szenarien die Einbeziehung räumlicher Information entscheidend ist. Während spektrale Verfahren wie der Wiener-Filter an ihre Grenzen stoßen, kann Beamforming die Fernfeldnachteile teilweise kompensieren und eine Transkriptionsqualität erreichen, die mit hochwertigen Einzelmikrofonen vergleichbar ist.

5.3 VERSUCH 3

Kernaussagen: In der erweiterten Mensa-Runde (6 Sprecher:innen, größere Distanzen) kippt der Vorteil zu den Einzelgeräten. Tabelle 5.3 zeigt:

- (i) Einzelgeräte (iPhone, Zoom) erreichen die niedrigste WER und hohen SA-Recall,
- (ii) DoA-Beamforming steigert beim Array vor allem den SA-Recall, die WER bleibt jedoch hoch,
- (iii) die Kombination aus DoA + Wiener ist unter den Array-Varianten am stärksten, bleibt aber hinter den Einzelgeräten.

System / Methode	WER [%]	SA-Recall [%]
ReSpeaker 4-Mic Array (Basis, Channel 0)	58.1	66.0
ReSpeaker + DoA-Beamforming	51.5	75.6
ReSpeaker + Wiener-Filter	49.3	66.2
ReSpeaker + DoA + Wiener-Filter	45.8	72.0
iPhone 12 mini	35.5	74.1
iPhone 12 mini + Wiener-Filter	31.6	75.2
Zoom H4n Pro	39.4	74.01
Zoom H4n Pro + Wiener-Filter	35.33	72.4

Tabelle 5.3: Vergleich der WER und des SA-Recall verschiedener Aufnahmesysteme und Signalverarbeitungsmethoden im dritten Aufnahmeszenario.

5.3.1 AUSWERTUNG VERSUCH 3

Das dritte Szenario (vgl. Tabelle. 5.3) stellt mit sechs Sprecher:innen, großen Abständen und starker Hintergrundkulisse die schwierigsten Bedingungen dar. In der Basisvariante des ReSpeaker-Arrays resultiert dies in einer hohen Fehlerrate (WER = 58.1 %, SA-Recall = 66.0 %). **DoA-Beamforming** stabilisiert zunächst vor allem die Sprecherattribution (SA-Recall = 75.6 %, +9.6 pp), reduziert die WER aber nur moderat (51.5 %, 6.6 pp; relative Reduktion 11.4 % ggü. der Basis). **Wiener-Filtering** wirkt dagegen ausgeprägter auf der Wortebene (WER = 49.3 %, 8.8 pp; 15.1 % relativ), beeinflusst die Attribution jedoch kaum (SA-Recall = 66.2 %, +0.2 pp). Die **Kombination aus DoA + Wiener** vereint die Stärken beider Schritte und erzielt die beste Array-Variante (WER = 45.8 %, 12.3 pp; 21.2 % relative Reduktion; SA-Recall = 72.0 %, +6.0 pp). Gleichzeitig bleibt die absolute Qualität trotz dieser Verbesserungen unzureichend. Die WER des Arrays liegt selbst mit DoA+Wiener deutlich über den Einzelgeräten, die in diesem Szenario robuster sind (iPhone 12 mini: 35.5 % ohne, 31.6 % mit Wiener; Zoom H4n Pro: 39.4 % ohne, 35.33 % mit Wiener). Die Aufwertung durch DoA/Wiener ist damit *relativ* klar (bis zu rund 21 % WER-Reduktion ggü. der Array-Basis), reicht aber *absolut* nicht aus, um die Low-Cost-Apertur-Limitationen in einem großflächigen, stark diffusen Mehrsprecherszenario zu kompensieren.

5.4 VERGLEICH DER SZENARIEN

Der Vergleich der drei Szenarien zeigt, dass die Leistungsfähigkeit des ReSpeaker-Arrays stark von den akustischen Rahmenbedingungen abhängt. In der ruhigen Besprechungssituation konnte das Array nach Anwendung von Wiener-Filter und DoA-Beamforming die Referenzgeräte teilweise übertreffen. Das stabile Signal-Rausch-Verhältnis ermöglichte eine effektive Unterdrückung von Hintergrundgeräuschen. Dadurch kamen die Vorteile der räumlichen Signalverarbeitung deutlich zum Tragen. Die Transkripte waren konsistent, weil die Diarisierung auf klar getrennte Sprechersegmente zugreifen konnte und weder Nachhall noch komplexes Übersprechen die Zuordnung beeinträchtigten.

In der Mensa-Situation mit moderatem Störpegel veränderte sich dieses Bild. Der niedrige Direct-to-Reverberant Ratio führte dazu, dass Nachhall fast gleich stark wie der Direktschall in den Aufnahmen vorhanden war. Der Wiener-Filter konnte diese diffuse Störung nicht zuverlässig reduzieren. Erst die Integration von DoA-basiertem Beamforming brachte eine Verbesserung, da die Signale kohärent in Zielrichtung addiert wurden und Störquellen aus anderen Winkeln zumindest teilweise abgeschwächt werden konnten. Diese Ergebnisse zeigen, dass spektrale Verfahren in halligen Räumen nicht ausreichen, weil sie zwar stationäres Rauschen dämpfen, jedoch keine räumliche Trennung von Schallquellen leisten. Noch deutlicher traten die Grenzen im erweiterten Mensa-Szenario mit sechs Sprecherinnen und Sprechern hervor. Trotz Nachbearbeitung lag die Wortfehlerrate hier deutlich höher als bei den Einzelmikrofonen. Technisch lässt sich dies auf die kleine Apertur des ReSpeaker-Arrays zurückführen. Mit einem Mikrofonabstand von acht Zentimetern liegt die aliasfreie Maximalfrequenz bei 2,137 kHz. Da für die Sprachverständlichkeit jedoch auch Frequenzanteile bis 8 kHz relevant sind, entstehen Grating Lobes und räumliches Aliasing mitten im Sprachband. Diese Effekte verfälschen die Richtschätzung des Beamformers, sodass die räumliche Verstärkung instabil wird und nicht mehr zuverlässig zwischen den verschiedenen Sprecherpositionen unterscheidet. Einzelmikrofone wie das Zoom H4n oder das iPhone sind von dieser Problematik nicht betroffen und lieferten daher robustere Ergebnisse.

Die in Abbildung 5.1 dargestellten Verläufe der WER verdeutlichen diesen Negativtrend eindrucklich, während das Array in Szenario 1 nach Signalverarbeitung noch konkurrenzfähig ist, verschlechtert sich die Fehlerquote in Szenario 3 drastisch, während die Einzelgeräte relativ stabile Werte halten. Auch die Entwicklung des SA-Recall in Abbildung 5.2 zeigt, dass die Robustheit der Sprecherzuordnung bei den Referenzgeräten bis auf einen Ausreißer weitgehend konstant bleibt, beim Array jedoch mit zunehmender Komplexität deutlich einbricht.

Zusammenfassend lässt sich festhalten, dass kompakte Arrays in kontrollierten Gesprächssituationen erhebliche Vorteile bieten können. Ihre Leistungsfähigkeit wird in halligen oder mehrsprecherdominanten Umgebungen jedoch durch physikalische Limitierungen eingeschränkt. Damit eignen sie sich in erster Linie für strukturierte Meetings oder Interviews in akustisch günstigen Räumen, während für komplexe Szenarien mit vielen Sprecherinnen und Sprechern leistungsfähigere Array-Geometrien oder verteilte Aufnahmesysteme erforderlich sind.




Abbildung 5.1: Vergleich der WER für alle Systeme und Signalverarbeitungen in drei Szenarien (niedriger ist besser).




Abbildung 5.2: Vergleich des SA-Recall für alle Systeme und Signalverarbeitungen in drei Szenarien (höher ist besser).

6 DISKUSSION

6.1 REFLEXION DER METRIKEN

Die verwendeten Metriken WER und SA-Recall liefern ein differenziertes Bild der Systemleistung. Während die WER stark von der Signalqualität beeinflusst wird und damit die Wirksamkeit von Rauschunterdrückung und Beamforming unmittelbar widerspiegelt, hängt der SA-Recall primär von der Robustheit der Diarisierung und der Konsistenz der Sprechersegmente ab [28, 17]. Auffällig ist, dass die Verbesserungen durch Postprocessing und Beamforming vor allem in der WER sichtbar werden, während der SA-Recall in allen Szenarien (bis auf einen Ausreißer) innerhalb eines vergleichsweise engen Korridors bleibt. Dies unterstreicht, dass die Stabilität der Sprecherzuordnung weniger von der akustischen Signalqualität als vielmehr von den eingesetzten Algorithmen zur Sprechertrennung bestimmt wird.

Darüber hinaus berücksichtigen beide Metriken keine semantischen oder syntaktischen Aspekte der Transkription, was ihre Aussagekraft in Bezug auf die tatsächliche Inhaltsqualität begrenzt. Eine Transkription kann trotz niedriger WER semantische Brüche enthalten, während eine höhere WER nicht zwangsläufig die Nutzbarkeit für Inhaltsanalysen ausschließt. Für eine umfassendere Bewertung wären daher ergänzende Kennzahlen wie die Semantic Error Rate (SemER), die Diarization Error Rate (DER) oder Interaktionsmetriken zwischen Sprecherwechseln sinnvoll, um die Anwendbarkeit in realen Gesprächssituationen besser abzubilden. Zukünftige Arbeiten sollten darüber hinaus untersuchen, inwieweit metrikübergreifende Ansätze (z. B. Kombination von WER, SA-Recall und semantischen Scores) robustere Aussagen über die Gesamtqualität ermöglichen.

6.2 EINORDNUNG IN PROBLEMSTELLUNG UND FORSCHUNGSSTAND

Die Evaluationsergebnisse bestätigen die in der Problemstellung formulierte Annahme, dass klassische Einzelmikrofone nur eingeschränkt für komplexe Gesprächssituationen geeignet sind. Während Zoom und iPhone in Szenarien mit geringer Sprecherzahl solide Ergebnisse erzielen, ermöglicht erst die Kombination aus Mikrofonarray und adaptiver Signalverarbeitung eine nachhaltige Verbesserung der Transkriptionsqualität. Allerdings zeigt sich im dritten Szenario auch die Grenze des eingesetzten Arrays. Eine geringe Apertur und die kreisförmige Anordnung mit vier Mikrofonen reduzieren die Richtschärfe insbesondere bei tiefen Frequenzen, was mit den in der Literatur beschriebenen Limitierungen kleiner Arrays übereinstimmt [15, 27]. Diese Beobachtung deckt sich mit aktuellen Forschungsarbeiten, die distributed arrays oder adaptive Beamformer höherer Ordnung vorschlagen, um auch in großskaligen Gesprächssituationen eine robuste Spracherkennung zu gewährleisten [16].

Darüber hinaus verdeutlichen die Ergebnisse, dass die Kombination klassischer Verfahren (Delay-and-Sum, Wiener-Filter) mit datengetriebenen Modellen wie Whisper zwar kurzfristig eine deutliche Verbesserung bringt, langfristig jedoch Grenzen sichtbar werden. Insbesondere in stark verrauschten, halligen oder dezentralisierten Szenarien zeigt sich, dass eine rein signalbasierte Optimierung nicht ausreicht. Forschungsarbeiten zu *all-neural beamforming*-Ansätzen deuten an, dass durch die Integration von Beamforming direkt in neuronale ASR-Modelle eine robustere Verarbeitung erreicht werden könnte. [15]

Praktisch bedeutet dies, dass kleine Arrays in kontrollierten Umgebungen (z. B. Besprechungsräume) bereits eine valide Alternative zu Einzelmikrofonen darstellen. Für komplexere Szenarien wie hybride Meetings, große Gruppen oder Umgebungen mit starkem Störgeräusch wird dagegen der Einsatz leistungsfähigerer Array-Geometrien oder verteilter Systeme notwendig. Auch die Echtzeitfähigkeit auf ressourcenschwacher Hardware, wie etwa dem Raspberry Pi, muss kritisch betrachtet werden. Während eine lokale Verarbeitung prinzipiell möglich ist, bleibt die Balance zwischen Rechenaufwand, Latenz und Transkriptionsqualität eine offene Herausforderung.

Insgesamt unterstreicht die Arbeit somit sowohl das Potenzial als auch die Grenzen kleiner Mikrofonarrays. Sie liefert empirische Hinweise darauf, dass deren Nutzen stark von der akustischen Situation abhängt und dass eine Weiterentwicklung in Richtung verteilter oder intelligenter adaptiver Arrays für realistische Anwendungsfelder essenziell ist.

6.3 STÄRKEN UND SCHWÄCHEN DER METHODIK

Anhand der Ergebnisse lassen sich einige Stärken feststellen. Zum einen erlaubt die Kombination aus SNR-basiertem Gating, Wiener-Filter und DoA-Beamforming eine nachvollziehbare, modulare Signalverarbeitung, die transparent analysiert werden kann. Zum anderen stellt die Nutzung von Whisper als robustem ASR-System sicher, dass Ergebnisse in realistischen Umgebungen erzielt werden.

Gleichzeitig sind jedoch Schwächen erkennbar. Die Tests beschränkten sich auf drei Szenarien mit vergleichsweise wenigen Sprecher:innen und fixen Array-Geometrien. Weitere Einflussfaktoren, wie Nachhallzeiten, Sprecherbewegungen oder unterschiedliche Raumgrößen, wurden nicht systematisch variiert. Auch wurden ausschließlich objektive Metriken betrachtet, ohne dass subjektive Hörtests zur Einschätzung der Sprachverständlichkeit durchgeführt wurden.

Ein bewusst gewählter limitierender Faktor ist die Hardware selbst. Das eingesetzte ReSpeaker 4-Mic Array v2.0 gehört zu den günstigen Systemen im unteren Preissegment und repräsentiert damit eine realistische Consumer-Lösung. Die geringe Mikrofonanzahl und die kostengünstigen Komponenten setzen dem erreichbaren Signal-Rausch-Verhältnis und der Richtschärfe enge physikalische Grenzen. Besonders relevant ist dabei die limitierte Arraygeometrie. Mit einer Apertur von lediglich acht Zentimetern liegt die aliasfreie Maximalfrequenz bei 2,137 kHz, sodass bereits im relevanten Sprachband räumliches Aliasing und Grating Lobes auftreten können. Dies schränkt die Stabilität der DoA-Schätzung und die Effektivität des Beamformings in realistischen Mehrsprecherszenarien erheblich ein. Die Wahl dieser Hardware ermöglicht jedoch eine praxisnahe Bewertung dessen, was mit verfügbarer, erschwinglicher Technologie erreichbar ist.

Die Verwendung eines einheitlichen Parametersatzes über alle Szenarien hinweg stellt methodisch eine bewusste Designentscheidung dar. Die empirische Validierung zeigte, dass die auf Basis von Szenario 1 optimierten Parameter auch für die komplexeren Szenarien 2 und 3 konsistent die besten Ergebnisse lieferten. Dies bestätigt die Robustheit des Ansatzes und dessen praktische Anwendbarkeit ohne szenario-spezifische Nachkalibrierung, ein entscheidender Vorteil für reale Einsatzfälle, in denen akustische Bedingungen vorab nicht bekannt sind.

6.4 PRAKTISCHE IMPLIKATIONEN

Aus praktischer Sicht zeigt die Arbeit, dass kompakte und kostengünstige Mikrofonarrays in ruhigen und moderat gestörten Umgebungen eine echte Alternative zu Einzelmikrofonen darstellen können. Besonders für Anwendungen wie Gremiensitzungen, journalistische Interviews oder hybride Besprechungen bieten sie den Vorteil einer flexiblen Raumabdeckung und der Möglichkeit, sprecherbezogene Transkripte automatisiert zu erzeugen.

Die Evaluierung zeigt klar die Grenzen günstiger Consumer-Hardware auf, definiert aber gleichzeitig deren praktischen Einsatzbereich. Das System um das Mikrofonarray erweist sich in kontrollierten Umgebungen (Versuch 1) als durchaus konkurrenzfähig zu etablierten Einzelmikrofonen. In komplexeren Szenarien wird jedoch deutlich, dass für professionelle Anwendungen Investitionen in hochwertigere Hardware mit größerer Apertur, optimierten Geometrien und besseren Komponenten erforderlich sind. Für Anwendungsfälle mit begrenztem Budget, etwa in Bildungseinrichtungen wie die Universität Bonn, kleinen Unternehmen oder als Proof-of-Concept-Systeme, bietet die untersuchte Lösung dennoch einen praktischen Nutzen. Die Ergebnisse liefern klare Kriterien, wann günstige Arrays ausreichend sind und wann höhere Investitionen gerechtfertigt werden. In großskaligen oder stark verrauschten Szenarien bleibt die Leistungsfähigkeit dagegen eingeschränkt. Dies legt nahe, dass günstige Arrays kurzfristig

gewinnbringend in Nischenanwendungen eingesetzt werden können, für universelle Lösungen aber noch erhebliche Weiterentwicklungen erforderlich sind.

7 FAZIT

Die vorliegende Arbeit untersucht systematisch die Leistungsfähigkeit eines kompakten Mikrofonarrays im Vergleich zu etablierten Einzelmikrofonen für die automatisierte Transkription von Gesprächssituationen. Die Ergebnisse zeigen deutlich, dass die Eignung solcher Systeme stark von den akustischen Rahmenbedingungen und den Anforderungen an die Transkriptionsqualität abhängt.

In kontrollierten Umgebungen mit geringer Teilnehmerzahl und niedrigem Störgeräuschpegel (Versuch 1) erreicht das Mikrofonarray nach geeigneter Signalverarbeitung eine Transkriptionsqualität, die etablierte Einzelmikrofone teilweise übertrifft. Die Kombination aus DoA-basiertem Beamforming und Wiener-Filter reduziert die Wortfehlerrate auf 24,6 % bei einem Speaker-Attributed Recall von über 80 %. Diese Ergebnisse belegen, dass räumliche Signalverarbeitung in ruhigen Besprechungssituationen einen klaren Mehrwert bietet.

In akustisch herausfordernden Szenarien zeigen sich jedoch die physikalischen Grenzen kompakter Low-Cost-Arrays deutlich. Die geringe Apertur von 8 cm führt zu räumlichem Aliasing oberhalb von 2.137 kHz, was die Richtschärfe im relevanten Sprachband erheblich beeinträchtigt. In der erweiterten Mensa-Situation mit sechs Sprechern (Versuch 3) bleibt die Wortfehlerrate trotz Nachbearbeitung bei 45,8 %, während Einzelmikrofone mit 31,6 – 35,5 % deutlich robustere Ergebnisse liefern.

7.1 WANN DAS ARRAY EINZELMIKROFONEN VORZUZIEHEN IST

Das ReSpeaker-Array bietet in folgenden Situationen klare Vorteile gegenüber Handy und Zoom H4n Pro. **Vollständige Automatisierung:** Der zentrale Vorteil des Arrays liegt in der Pipeline-Integration. Einmal aufgebaut, läuft der gesamte Prozess, von der Aufnahme über die Signalverarbeitung bis zur Transkription mit Sprecherzuordnung, automatisiert ab. Bei Smartphone-Aufnahmen müssten dagegen alle Schritte manuell durchgeführt werden: Audiodatei übertragen, in ASR-System hochladen, Transkript manuell nachbearbeiten, Sprecher von Hand zuordnen. Dieser Workflow-Vorteil wird besonders bei regelmäßigen Meetings relevant, bei denen sich die einmalige Einrichtung des Arrays schnell amortisiert. **Räumliche Flexibilität:** Die 360°-Erfassung mit adaptivem Beamforming ermöglicht gleichberechtigte Teilnahme aller Personen, ohne dass jemand das Mikrofon bedienen oder in eine bestimmte Richtung sprechen muss. Die räumliche Information unterstützt zudem pyannote.audio bei der Diarisierung, was sich in konsistenteren Speaker-Labels niederschlägt, wichtig für die spätere Durchsuchbarkeit der Transkripte.

Geeignete Einsatzszenarien:

- Strukturierte Meetings mit bis zu vier Teilnehmern in ruhigen Räumen
- Journalistische Interviews in kontrollierten Umgebungen
- Gremiensitzungen mit fester Sitzordnung und geringem Hintergrundgeräusch
- Hybride Besprechungen mit zentraler Tischposition
- Prototyping und Proof-of-Concept-Anwendungen mit begrenztem Budget
- Situationen mit häufiger Nutzung, bei denen sich die Automatisierung amortisiert

Für alltägliche, organisatorische Besprechungen, bei denen eine moderate Fehlerrate akzeptabel ist und die Dokumentation primär der Gedächtnisstütze dient, stellt das ReSpeaker-Array somit eine kostengünstige und praktikable Lösung dar.

7.2 WANN EINZELMIKROFONE ODER ALTERNATIVE LÖSUNGEN NÖTIG SIND

Bei mehr als 4 – 5 Sprechern: Die Ergebnisse aus Szenario 3 (6 Personen, große Abstände) zeigen die klaren Grenzen: Das Array erreicht selbst mit voller Nachbearbeitung nur 45,8 % WER gegenüber 31,6 – 35,5 % bei Einzelmikrofonen. Für solche Situationen sind folgende Alternativen sinnvoller:

- Individuelle Smartphone-Aufnahmen als Backup mit manueller Nachbearbeitung

- Schriftliche Eigennotizen der Teilnehmenden, die später konsolidiert werden
- Hochwertigere Array-Systeme mit größerer Apertur (>20 cm Mikrofonabstand) und mehr Mikrofonen
- Verteilte Mikrofonsysteme mit mehreren koordinierten Aufnahmepunkten

Weitere ungeeignete Szenarien:

- Laute Umgebungen mit hohem diffusem Störgeräuschpegel (z. B. Großraumbüros, Cafés, Mensa)
- Kritische Aufnahmen, bei denen eine niedrige Fehlerrate essentiell ist (z. B. Vertragsverhandlungen, rechtlich relevante Protokolle, medizinische Dokumentation, wissenschaftliche Interviews mit Fachterminologie)
- Dynamische Gesprächssituationen mit häufigen Sprecherwechseln und Bewegung im Raum
- Stark hallige Räume mit niedriger Direct-to-Reverberant Ratio (vgl. Kapitel 2.4.5)

Für wichtige Meetings, bei denen die Transkriptionsqualität kritisch ist, sollten hochwertige Einzelmikrofone (wie das Zoom H4n Pro) oder professionelle Array-Systeme mit größerer Apertur und optimierter Geometrie eingesetzt werden. Die in dieser Arbeit dokumentierte Fehlerrate von über 45 % in komplexen Szenarien ist für solche Anwendungen nicht akzeptabel.

7.3 AUSBLICK

Zukünftige Forschungsarbeiten sollten in mehreren Richtungen ansetzen:

- **Erweiterte Metriken:** Neben WER und SA-Recall sollten semantische und interaktive Kennzahlen wie SemER oder DER integriert werden, um die tatsächliche Gesprächsqualität besser abzubilden.
- **Größere und flexiblere Array-Geometrien:** Untersuchungen mit kreisförmigen oder verteilten Arrays könnten die Richtschärfe und Robustheit gegenüber Störschall verbessern. Der Übergang zu zirkulären Arrays mit höherer Mikrofonanzahl und besseren Komponenten würde die hier identifizierten physikalischen Limitationen beheben.
- **Integration neuronaler Modelle:** Der Übergang zu all-neural Beamforming-Ansätzen und die engere Kopplung von Signalverarbeitung und ASR könnten eine robustere Performance in komplexen Szenarien ermöglichen.
- **Adaptive Parametrisierung:** Zukünftige Systeme sollten maschinelle Lernverfahren integrieren, die Signalverarbeitungsparameter automatisch an die akustische Umgebung anpassen. Dies würde die in dieser Arbeit durchgeführte manuelle Optimierung durch intelligente, selbstlernende Algorithmen ersetzen und robuste Performance über verschiedene Szenarien hinweg ermöglichen.
- **Subjektive Evaluation:** Hörtests mit Proband:innen könnten wertvolle Erkenntnisse darüber liefern, wie technische Verbesserungen tatsächlich wahrgenommen werden.
- **Echtzeitfähigkeit:** Die Optimierung von Pipelines für ressourcenschwache Hardware wie Raspberry Pi oder Edge-Geräte bleibt eine zentrale Herausforderung, insbesondere im Hinblick auf Latenz und Energieeffizienz.
- **Kosten-Leistungs-Trade-off:** Künftige Arbeiten sollten systematisch untersuchen, wie sich Preis, Bauteilqualität und Array-Geometrie auf die Transkriptionsqualität auswirken. Gerade für praxisnahe Anwendungen ist die Frage entscheidend, ob günstige Arrays durch clevere Signalverarbeitung konkurrenzfähig gemacht werden können oder ob hochwertige Hardware unverzichtbar bleibt.

Die vorliegende Arbeit demonstriert damit sowohl das Potenzial als auch die klaren Grenzen aktueller Low-Cost-Lösungen. Sie liefert klare Kriterien, wann günstige Arrays ausreichend sind und wann höhere Investitionen gerechtfertigt werden. Insgesamt eröffnet die Arbeit wichtige Anschlussfragen für die Weiterentwicklung kompakter Mikrofonarrays und deren Integration in praktische Systeme und bietet eine Grundlage für zukünftige Investitionsentscheidungen in der automatisierten Gesprächsaufzeichnung.

LITERATUR

- [1] Ahmed Ali und Steve Renals. „Word Error Rate Estimation for Speech Recognition: e-WER“. In: *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers)*. Hrsg. von Iryna Gurevych und Yusuke Miyao. Melbourne, Australia: Association for Computational Linguistics, Juli 2018, S. 20–24. DOI: [10.18653/v1/P18-2004](https://doi.org/10.18653/v1/P18-2004). URL: <https://aclanthology.org/P18-2004/>.
- [2] Apple Inc. *iPhone 12 mini – Technical Specifications*. <https://support.apple.com/en-us/111877>. Accessed: 2025-09-25. 2025.
- [3] Jacob Benesty, Jingdong Chen und Yiteng Huang. *Microphone Array Signal Processing*. Berlin / Heidelberg: Springer, 2008. ISBN: 978-3-540-78612-2. DOI: [10.1007/978-3-540-78612-2](https://doi.org/10.1007/978-3-540-78612-2).
- [4] Hervé Bredin und contributors. *pyannote.audio Documentation*. <https://docs.pyannote.ai/introduction>. Accessed: 2025-09-25. 2025.
- [5] Alessio Brutti und Marco Matassoni. „On the use of Early-to-Late Reverberation Ratio for ASR in reverberant environments“. In: Mai 2014. DOI: [10.1109/ICASSP.2014.6854481](https://doi.org/10.1109/ICASSP.2014.6854481).
- [6] Niklas Busler. *Sprache-zu-Text mit OpenAI Whisper auf dem Raspberry Pi 5*. Accessed on: 2025-07-08. 2025. URL: <https://buyzero.de/blogs/news/sprache-zu-text-mit-openai-whisper-auf-dem-raspberry-pi-5>.
- [7] Weiping Cai, Shikui Wang und Zhenyang Wu. „Accelerated steered response power method for sound source localization using orthogonal linear array“. In: *Applied Acoustics* 71.2 (2010), S. 134–139. ISSN: 0003-682X. DOI: <https://doi.org/10.1016/j.apacoust.2009.07.015>. URL: <https://www.sciencedirect.com/science/article/pii/S0003682X0900173X>.
- [8] Fei Chen und Philippos C. Loizou. „Impact of SNR and gain-function over- and under-estimation on speech intelligibility“. In: *Speech Communication* 54.2 (2012), S. 272–281. ISSN: 0167-6393. DOI: <https://doi.org/10.1016/j.specom.2011.09.002>. URL: <https://www.sciencedirect.com/science/article/pii/S0167639311001348>.
- [9] Peter Derleth u. a. „Binaural Signal Processing in Hearing Aids“. In: *Seminars in Hearing* 42 (Aug. 2021), S. 206–223. DOI: [10.1055/s-0041-1735176](https://doi.org/10.1055/s-0041-1735176).
- [10] Joseph DiBiase. „A high-accuracy, low-latency technique for talker localization in reverberant environments using microphone arrays /“. In: (Aug. 2000).
- [11] DSP Concepts. *Hysteresis Module – Audio Weaver Designer Documentation*. <https://documentation.dspconcepts.com/awe-designer/8.D.2.2/hysteresis>. Accessed: 2025-09-30. 2025.
- [12] ESB Solutions GmbH. *Richtcharakteristik – Handbuch Grundbegriffe und Einheiten*. <https://esbsolutions.de/sprachalarmierung/handbuch-grundbegriffe-einheiten/richtcharakteristik/>. Accessed: 2025-09-30. 2025.
- [13] Jørgen Hald und J Christensen. „A class of optimal broadband phased array geometries designed for easy construction“. In: Aug. 2002.
- [14] Osamu Hoshuyama, Akihiko Sugiyama und Akihiro Hirano. „A robust adaptive beamformer for microphone arrays with a blocking matrix using constrained adaptive filters“. In: *IEEE Transactions on signal processing* 47.10 (2002), S. 2677–2684.

- [15] Gongping Huang u. a. „Advances in Microphone Array Processing and Multichannel Speech Enhancement“. In: *arXiv preprint arXiv:2502.09037* (2025).
- [16] Naoyuki Kamo u. a. „Microphone Array Geometry Independent Multi-Talker Distant ASR: NTT System for the DASR Task of the CHiME-8 Challenge“. In: *arXiv preprint arXiv:2502.09859* (2025).
- [17] Naoyuki Kanda u. a. *Transcribe-to-Diarize: Neural Speaker Diarization for Unlimited Number of Speakers using End-to-End Speaker-Attributed ASR*. 2022. arXiv: 2110.03151 [eess.AS]. URL: <https://arxiv.org/abs/2110.03151>.
- [18] Gitte Keidser u. a. „The effect of frequency-dependent microphone directionality on horizontal localization performance in hearing-aid users“. In: *International Journal of Audiology* 48.11 (2009). PMID: 19951147, S. 789–803. DOI: 10.3109/14992020903036357. eprint: <https://doi.org/10.3109/14992020903036357>. URL: <https://doi.org/10.3109/14992020903036357>.
- [19] Wiggers Kyle. *Amazon’s AI Uses a Microphone Array to Localize Multiple Speakers in a Room*. Accessed on: 2025-07-08. 2020. URL: <https://venturebeat.com/ai/amazons-ai-uses-a-microphone-array-to-localize-multiple-speakers-in-a-room/>.
- [20] Thilo von Neumann u. a. „Word Error Rate Definitions and Algorithms for Long-Form Multi-Talker Speech Recognition“. In: *IEEE Transactions on Audio, Speech and Language Processing* 33 (2025), S. 3174–3188. ISSN: 2998-4173. DOI: 10.1109/taslpro.2025.3589862. URL: <http://dx.doi.org/10.1109/TASLPRO.2025.3589862>.
- [21] Alec Radford u. a. *Whisper: OpenAI’s automatic speech recognition system*. <https://openai.com/research/whisper>. Accessed: 2025-07-08. 2022.
- [22] Raspberry Pi Foundation. *Raspberry Pi OS Documentation*. <https://www.raspberrypi.com/documentation/computers/os.html>. Accessed on: 22.09.2025. 2025.
- [23] Seeed Studio. *ReSpeaker Mic Array v2.0 Wiki*. Accessed on: 2025-07-08. 2025. URL: https://wiki.seeedstudio.com/ReSpeaker_Mic_Array_v2.0/.
- [24] B.D. Van Veen und K.M. Buckley. „Beamforming: a versatile approach to spatial filtering“. In: *IEEE ASSP Magazine* 5.2 (1988), S. 4–24. DOI: 10.1109/53.665.
- [25] Sung Woo. *Whisper: A Breakthrough in Speech Recognition AI*. Accessed on: 2025-07-08. 2025. URL: <https://medium.com/@enerzai/whisper-a-breakthrough-in-speech-recognition-ai-007aa5abf736>.
- [26] Xiong Xiao u. a. „A Study of Learning Based Beamforming Methods for Speech Recognition“. In: *Proceedings of the 4th International Workshop on Speech Processing in Everyday Environments (CHiME 2016)*. San Francisco, CA, USA, Sep. 2016, S. 26–31. URL: https://www.chimechallenge.org/workshops/chime2016/papers/CHiME_2016_paper_17.pdf.
- [27] Takuya Yoshioka u. a. „Meeting transcription using virtual microphone arrays“. In: *arXiv preprint arXiv:1905.02545* (2019).
- [28] Fan Yu u. a. *A Comparative Study on Speaker-attributed Automatic Speech Recognition in Multi-party Meetings*. 2022. arXiv: 2203.16834 [cs.SD]. URL: <https://arxiv.org/abs/2203.16834>.
- [29] Mateusz Żbik, Giulio Cengarle und Daniel Arteaga. *Deep learning based spatial aliasing reduction in beamforming for audio capture*. Mai 2025. DOI: 10.48550/arXiv.2505.19781.

- [30] Zoom Corporation. *Zoom H4n Pro Handy Recorder*. <https://zoomcorp.com/en/de/handheld-recorders/handheld-recorders/h4n-pro/>. Accessed: 2025-09-25. 2025.

8 ANHANG

8.1 GITHUB REPOSITORY

Algorithmen finden sich unter:

<https://github.com/shajanrazani/Projektgruppe-UseCap-Einsatz-von-Mikrofonarray>
git